

面向间歇羽流的双触须主动嗅觉采样与强化学习搜索方法

论文初稿（修订版）

基于 GitHub 仓库 dual-whisker-rl 当前代码结构整理

作者：_____

单位：_____

日期：2026年8月

说明：本文为方法与实验设计初稿。仓库中尚未形成可直接支撑性能结论的正式多随机种子实验和完整真机结果，因此本文区分“已实现的方法”“已完成的连通性验证”和“待验证的研究假设”；所有需要后续数据支撑的位置均以“【待补】”标记。

目录

摘要	5
符号与缩略语说明	6
1 引言	6
1.1 研究背景	6
1.2 问题定义与核心挑战	7
1.3 相关研究与本文切入点	8
1.4 本文技术路线与主要工作	8
1.5 文章结构	9
2 自适应嗅觉触须硬件系统设计	9
2.1 系统总体结构	9
2.2 双触须几何与执行机构设计	9
2.3 气体传感器与标定/预处理	10
2.4 硬件电路与接口	11
2.5 嵌入式控制流程	11
2.6 仿真—真机观测语义一致性	11
3 双触须主动采样与强化学习搜索算法	12
3.1 部分可观测决策建模	12
3.1.1 固定基座主动采样任务	12
3.1.2 移动机器人联合搜索任务	12
3.2 动态羽流与嗅觉采样模型	12
3.3 差速机器人运动模型	13
3.4 非对称气体传感器动态	13
3.5 观测状态设计	13
3.6 联合动作空间设计	14
3.7 历史窗口与时序数据特征提取	15
3.7.1 MLP 历史基线	15
3.7.2 GRU 时序编码器	15
3.7.3 Transformer 时序编码器	15

3.8 Actor-Critic 网络结构	16
3.9 PPO 算法的理论推导：从策略梯度到近端更新	17
3.9.1 从轨迹概率到策略梯度	17
3.9.2 基线为何能够降低方差而不引入偏差	17
3.9.3 从 TD 残差到多步优势估计	18
3.9.4 广义优势估计 GAE 的由来	18
3.9.5 从策略梯度到重要性采样代理目标	19
3.9.6 为什么需要信赖域与 KL 散度	19
3.9.7 从 KL 惩罚到 PPO-Clip	20
3.9.8 Actor、Critic 与熵正则的联合目标	20
3.10 奖励函数设计	21
3.10.1 距离差分奖励	21
3.10.2 历史最佳浓度增量奖励	21
3.10.3 触须独立重捕获奖励	22
3.10.4 时间与停滞惩罚	22
3.10.5 终止奖励与越界惩罚	22
3.11 一轮 PPO 训练的完整流程	22
3.12 算法设计的关键逻辑	23
4 仿真环境与参数优化	23
4.1 动态仿真环境搭建与物理参数	24
4.2 域随机化策略	24
4.3 Actor-Critic 与时序模型参数优化	25
4.4 仿真训练的数据流与参数更新机制	25
4.4.1 从动态羽流到 rollout buffer 的数据流	26
4.4.2 从奖励序列生成优势与价值目标	27
4.4.3 minibatch 前向计算与三类误差函数	27
4.4.4 反向传播经过哪些网络参数	28
4.4.5 梯度裁剪与 Adam 参数更新	28
4.4.6 多轮样本复用、KL早停与下一轮采样	29
4.4.7 网络梯度优化与实验超参数优化的关系	29
4.5 奖励函数的优化逻辑	29
4.6 观测值的优化	30
4.7 动作空间的优化	30

4.8 训练稳定性诊断	31
4.9 统一评估指标	31
4.10 建议的正式调参协议	32
5 实验设计与讨论	32
5.1 实验设置	32
5.2 固定基座主动采样实验	33
5.3 移动任务消融实验设计	33
5.4 与其他算法/采样策略的对比	34
5.5 预期分析维度与结果解释原则	34
5.6 方法优势	35
5.7 当前不足与局限	35
5.8 后续真机实验建议	35
6 结论与展望	35
附录A 当前代码关键参数汇总	36
附录B 论文内容与代码模块对应关系	37
参考文献（初稿建议）	37
初稿后续补充清单	38

摘要

湍流输运使气味羽流呈现间歇、破碎且随时间漂移的 whiff/blank 结构，金属氧化物气体传感器又具有响应滞后、恢复缓慢和基线漂移等特性，因此固定安装传感器得到的单点瞬时读数往往不足以稳定表征局部气味状态。本文研究的首要问题不是沿光滑浓度梯度爬升，而是：在机器人本体不动或运动条件受控时，主动改变两路气体传感器的空间采样位置，能否比固定姿态或预设扫描获得更多有效气味信息。为此，本文设计左右独立摆动的双嗅觉触须，每侧离散为 10 个采样扇区，并建立两级验证框架：首先在固定基座环境中比较主动策略、多个固定角度、周期扫描和随机扫描的信息获取能力；随后在移动搜索环境中，将底盘动作与左右触须扇区组成联合动作，使用近端策略优化（Proximal Policy Optimization, PPO）考察主动采样能否转化为更好的气味重捕获与找源表现。策略观测由双路传感器相对信号、平滑量、短时趋势、左右差分、触须几何以及可由底盘侧重建的本体信息构成，不输入真实气源位置、真实风向或到源距离。针对慢响应信号，本文使用固定长度历史窗口，并实现 MLP、GRU 与 Transformer 三类时序编码器。仿真采用动态 puff 羽流、非对称气体传感器模型和可选域随机化；移动任务奖励由距离差分、历史最佳浓度增量、纯触须重捕获、时间与终止项组成，并设置反投机约束。本文当前完成了系统、算法、仿真与评估链路，正式多随机种子实验和真机对照仍待完成，因此现阶段贡献是提出可复现的主动采样建模与证据链，而不预先宣称主动触须已取得性能提升。

关键词：主动嗅觉；主动采样；双触须；气味源定位；深度强化学习；动态羽流；时序建模

符号与缩略语说明

符号/缩写	含义
OSL	Odor Source Localization, 气味源定位
POMDP	Partially Observable Markov Decision Process, 部分可观测马尔可夫决策过程
PPO	Proximal Policy Optimization, 近端策略优化
GAE	Generalized Advantage Estimation, 广义优势估计
A-C	Actor-Critic, 策略网络—价值网络结构
s_t	t 时刻不可完全观测的环境状态
o_t	t 时刻智能体可获得的单帧观测
H_t	截至 t 时刻的有限观测历史, $H_t=(o_{t-H+1}, \dots, o_t)$
a_t	t 时刻的联合动作
r_t	执行 a_t 后获得的即时奖励
π_θ	参数为 θ 的策略
v_π	策略 π 下的状态价值函数; v_ϕ 表示 Critic 的参数化近似
q_π	策略 π 下的动作价值函数
A_π	策略 π 下的优势函数; A_t^π 表示样本优势估计
$\rho_t(\theta)$	PPO 中新策略相对旧策略的动作概率比
δ_t	TD 残差
$R_t^\wedge$	由 GAE 优势和旧价值构造的 Critic 回归目标
l_t	真实终止指示量; 终止时取1, 否则取0
H	历史观测窗口长度, 当前训练脚本默认 H=20
χ_t	机器人位姿向量 $[x_t, y_t, \psi_t]^T$
u, ω	机器人线速度与角速度
d_t	机器人在 t 时刻到气源的欧氏距离, 仅用于训练奖励和评估
c_t^L, c_t^R	左右触须位置处经传感器动态后的读数
b_t	失嗅持续时间 (blank age)

1 引言

1.1 研究背景

气味源定位 (Odor Source Localization, OSL) 的目标是在缺乏直接视线或目标几何先验的情况下, 利用空气中传播的化学信息推断并到达气体释放源。机器人嗅觉研究通常把任务划分为羽流发现、羽流追踪和气源确认, 已有方法包括反应式/梯度式搜索、仿生轨迹、概率推断、信息驱动搜索以及学习方法[5,8-9]。然而, 气味并不是稳定、光滑的标量场。湍流输运使羽流在空间上呈条带、团簇与间断结构, 同一固定位置往往经历“闻到—失去—再次闻到”的 whiff/blank 交替过程, 机器人在局部时刻观测到的浓度上升或下降并不必然对应其与气源距离的单调变化。

传统移动电子鼻通常将一个或多个气体传感器固定安装在机器人本体上，采样位置由底盘运动唯一决定。这种结构的主要问题是“感知动作”与“位移动作”耦合：机器人若希望横向探测羽流边界、比较左右浓度或在失嗅后快速重捕获气味，必须移动或转动整个底盘。相比之下，可主动摆动的嗅觉触须能够在机器人本体位置不变或小幅变化时改变局部采样点，以较低运动代价获取更丰富的空间信息。因此，主动触须不只是一个机械结构问题，更自然地形成“选择在哪里采样”的主动感知问题。

另一方面，MQ-3 等金属氧化物气体传感器具有明显的动态滞后。其输出包含响应与恢复时间常数、基线变化和测量噪声，瞬时 ADC 值既反映当前气味刺激，也包含过去若干时刻刺激的记忆。因此，若仅将单帧读数输入控制器，系统实际上面对明显的状态混叠：相同的当前数值可能对应“浓度正在上升”“浓度正在下降”或“传感器尚未恢复”等不同情形。已有湍流羽流强化学习研究也表明，气味间歇和风向变化会提高对时间记忆的需求[10-12]。该特性要求搜索策略同时处理空间主动采样和时间信息整合。

1.2 问题定义与核心挑战

本文首先检验一个比“机器人最终是否到源”更基础、也更容易归因的问题：在二维间歇气味羽流中，当机器人本体位置和实验时序受到控制时，主动选择左右两根触须的采样扇区，能否比固定角度、周期扫描或随机扫描获得更多有效气味信息。这里的“更多信息”需要由预先定义的可测指标体现，包括气味命中率、趋势变化、左右差分、重捕获时间和扇区覆盖，而不能只由强化学习回报替代。

在上述假设得到支持后，本文再研究下游问题：差速移动机器人能否联合控制底盘和双触须，仅依赖硬件可重建的嗅觉与本体观测，从下风侧初始状态搜索到气源附近。采用这一两级问题定义，是为了避免把底盘移动、距离奖励或网络结构带来的性能变化误归因于主动触须。与单纯浓度爬坡相比，该问题至少包含以下五类困难。

- 羽流间歇性：局部浓度存在明显断续，瞬时梯度不稳定，机器人需要利用更长时间尺度的“命中—失嗅—重捕获”结构。
- 传感器记忆性：气体传感器响应与恢复存在滞后，观测并非环境真实浓度的即时映射。
- 感知—行动耦合：左右触须的扇区选择会改变下一步获得的信息，属于主动感知；底盘动作同时影响机器人位置、朝向与触须的全局采样位置。
- 仿真到真机一致性：如果策略依赖真实风向、气源距离等仿真内部量，即使仿真成功也无法直接部署，因此必须从算法设计阶段限制观测信息。
- 因果归因：移动找源成功率同时受底盘策略、奖励塑形、时序网络和触须动作影响，必须使用同算法、同训练预算且仅改变触须控制方式的基线隔离主动采样贡献。

1.3 相关研究与本文切入点

机器人气味源定位已形成较完整的方法谱系。早期和经典工作主要使用浓度阈值、上风运动、横风 casting、概率推断或信息增益选择移动位置[5,8-9]。Infotaxis 的代表性意义在于把搜索动作理解为降低源位置不确定性，而不是追逐不稳定的瞬时梯度[5]。近年来，深度强化学习被用于求解嗅觉搜索 POMDP；循环神经网络策略能够在间歇羽流中整合历史气味与本体线索，并出现与生物羽流追踪相似的行为模式[10-12]。这类研究说明“记忆 + 决策”适合处理断续气味，但研究动作通常仍以移动平台导航为中心。

与上述路线相比，本文把传感器采样几何本身设为可控变量：机器人左右两侧各有一个可独立摆动的传感器端点，策略可以在不旋转整个底盘的情况下改变局部采样位置。该设计与固定多传感器阵列不同，也不同于预设周期扫描；它关注的是策略能否根据近期 whiff/blank、趋势和左右差异自适应决定下一次在哪里采样。本文不把“可动触须”本身视为已证明的创新效果，而通过固定基座信息获取实验和移动找源对照建立证据链。

仿真方面，GADEN 等系统使用 CFD 风场与 filament 模型构建三维机器人嗅觉环境[13]，物理真实性高但计算与场景准备成本也较高。本文使用计算量较低的二维动态 puff 模型开展算法迭代，并把三维流动、障碍物反馈和机器人扰流明确列为外部有效性限制，而不将该模型表述为真实流场的精确替代。

1.4 本文技术路线与主要工作

围绕上述问题，本文构建“固定基座主动采样验证—硬件触须与观测适配—时序特征提取—Actor-Critic 联合策略—动态羽流仿真—移动找源验证”的技术路线。固定基座阶段先隔离触须采样动作的贡献；移动阶段再把左右触须扇区与机器人移动动作置于 MultiDiscrete 联合动作空间中，使策略能够学习何时移动本体、何时改变触须位置以及两者如何协同。

本文当前版本的主要工作可归纳为以下几点：

1. 设计双侧 180° 独立嗅觉触须采样结构，每侧离散为 10 个扇区，并在仿真中加入舵机速度约束，使采样动作具有实际执行时间语义。
2. 构建面向真机部署的观测表示。双路传感器读数采用与硬件端一致的基线扣除、EMA 平滑、趋势估计和归一化流程，并显式排除真实气源位置、真实风向和瞬时真实浓度等特权信息。
3. 建立固定长度历史观测与 MLP/GRU/Transformer 可切换的时序编码框架，并将时序特征送入 PPO 的 Actor-Critic 网络。
4. 提出面向奖励投机抑制的复合奖励：以距离差分提供全局训练塑形，以历史最佳浓度增量避免“保持高浓度反复得分”，以触须独立重捕获奖励强化主动采样价值，同时引入时间、停滞和越界成本。
5. 构建动态 puff 羽流和非对称慢响应传感器仿真，并支持羽流物理参数、传感器响应参数和场景初始化的随机化，为后续 sim-to-real 与鲁棒性实验提供基础。
6. 建立分层评估指标体系：固定基座阶段以命中、趋势、左右差分和重捕获等信息指标检验主动采样；移动阶段再考察成功率、路径、失嗅时长和重捕获归因。

1.5 文章结构

第2章介绍双嗅觉触须硬件系统、传感器处理、控制电路与嵌入式通信；第3章建立固定基座主动采样和移动搜索两级决策模型，并说明时序编码、Actor-Critic、PPO 更新和奖励函数；第4章给出动态羽流、域随机化、训练参数和诊断方法；第5章按“固定基座信息增益—移动找源转化—真机验证”的证据链设计实验，并讨论局限；第6章总结本文并给出后续工作。

2 自适应嗅觉触须硬件系统设计

2.1 系统总体结构

系统目标架构由移动底盘、左右两套嗅觉触须、两路气体传感器、STM32 下位机以及 PC/上位机策略计算模块组成。触须末端的气体传感器随舵机摆动，从而在机器人左右两侧半平面内选择不同空间位置进行采样。STM32 负责 PWM 舵机控制、ADC 采样与串口通信；上位机负责传感器预处理、历史状态维护和策略推理。当前已实现的是“双触须—STM32—上位机”的最小闭环，移动底盘控制、编码器/IMU 航向获取与统一时间同步仍需在真机移动实验前接入。因此，本章区分已实现的触须采样接口与待集成的完整移动平台，避免把软件目标架构表述为已完成硬件系统。

当前代码中的通信语义与强化学习动作保持一致：强化学习输出左、右触须扇区编号，硬件协议接受 STEP left_sector right_sector，并返回左右扇区及两路 ADC 读数。这样，策略层不需要直接处理 PWM 脉宽等执行细节，仿真与真机之间的接口差异被限制在硬件驱动层。

2.2 双触须几何与执行机构设计

左右触须分别覆盖机器人本体左侧和右侧的 180° 半平面。设每侧触须长度为 l ，机器人位姿为 $x_t = [x_t, y_t, \psi_t]^T$ ，左、右触须相对机器人航向的角度分别为 φ_t^L 与 φ_t^R ，则两个采样点的全局坐标为：

$$\begin{aligned} p_t^L &= [x_t + l\cos(\psi_t + \varphi_t^L), y_t + l\sin(\psi_t + \varphi_t^L)]^T \\ p_t^R &= [x_t + l\cos(\psi_t + \varphi_t^R), y_t + l\sin(\psi_t + \varphi_t^R)]^T \end{aligned}$$

当前 WhiskerOnlyPuffEnv 及其移动子环境默认触须长度 $l=0.15\text{ m}$ ，每侧划分为 10 个等角扇区；DualWhiskerSampler 类的独立构造默认值为 0.3 m ，但环境初始化会显式覆盖为 0.15 m ，论文参数以实际环境值为准。第 k 个扇区的中心角由 $(k+0.5)\pi/10$ 给出，因此左触须取 $+9^\circ$ 、 $+27^\circ$ 、...、 $+171^\circ$ ，右触须取 -9° 、 -27° 、...、 -171° 。这一离散化有两个目的：一是与有限精度舵机和串口命令天然匹配，二是把触须控制转化为离散主动采样决策，避免在项目第一阶段额外引入连续动作控制的训练复杂度。

仿真并未假设舵机可以瞬间跳到目标角，而是按照舵机角速度限制逐步逼近目标扇区。以当前参数 $60^\circ/0.12\text{ s}$ 估算最大角速度，并根据仿真步长限制单步最大转角。这样，策略若连续选择跨越很大的扇区，实际触须也需要多个物理时间尺度完成运动，从而降低“仿真中瞬移、真机中无法实现”的动作语义偏差。

2.3 气体传感器与标定/预处理

本项目当前硬件配置使用两路 MQ-3 模拟输出作为嗅觉信号。需要区分“物理浓度标定”和“策略输入预处理”两个层次。前者用于建立标准气体浓度与 ADC 输出之间的定量映射，属于硬件实验；后者的目标是把具有漂移、滞后和噪声的 ADC 序列转换为对强化学习更稳定的相对特征。当前仓库已经完整实现后者，但尚无足够的标准浓度标定实验数据，因此论文初稿不虚构标定曲线。

【待补：使用标准乙醇/目标气体浓度，在固定温湿度条件下记录两只 MQ-3 的稳态 ADC、响应时间、恢复时间和重复性，给出浓度—ADC 标定曲线、 R^2 、个体差异与误差范围。】

在线预处理首先维护缓慢变化的基线 B_t ，并由原始读数 x_t 计算相对信号 $\tilde{x}_t = x_t - B_t$ 。之后使用指数滑动平均抑制高频噪声，记平滑信号为 $\bar{x}_t$ ：

$$\alpha_s = \exp(-(\Delta t)/(\tau_s)), \bar{x}_t = \alpha_s \bar{x}_{t-1} + (1-\alpha_s) \tilde{x}_t$$

其中 Δt 为采样周期， τ_s 为平滑时间常数。当前预处理默认 $\tau_s = 2 \text{ s}$ 。为了表达“最近在上升还是下降”，在长度为 W 的平滑历史窗口内计算平均每步趋势：

$$g_t = (\bar{x}_t - \bar{x}_{t-W+1}) / (W-1)$$

为了缓解不同传感器幅值和不同上电基线造成的尺度差异，对信号、平滑量和趋势按尺度 S 归一化并进行裁剪：

$$\text{norm}(u) = \text{clip}(((u)/(S)), -C, C)$$

其中 S 不是跨仿真和真机共用的绝对常数，而是各信号域中“一次典型气味刺激变化量”的标度。当前仿真环境使用 $S=0.35$ ；阶段一硬件数据分析得到的暂定值为 $S=1500 \text{ ADC}$ ，并被硬件采样模式对比脚本采用；`SensorPreprocessConfig` 中的 $S=200$ 只是通用回退默认值，不应作为论文最终硬件标定值。裁剪幅度当前为 $C=5$ 。基线并非每帧都更新，而只在归一化平滑信号与趋势均较小时缓慢跟踪原始值，从而尽量避免在明显气味刺激期间把响应吸收到基线中。已有数据同时表明，慢恢复尾段仍可能被基线更新部分抵消，因此正式硬件实验需报告是否冻结基线，并对 `baseline_tau_s` 做敏感性分析。

表2-1 传感器在线预处理当前参数与适用范围

预处理参数	仿真环境	硬件阶段暂定值	作用
采样间隔 <code>dt_s</code>	0.2 s	约0.8 s或按实测时间戳	预处理时间尺度
基线时间常数 <code>baseline_tau_s</code>	180 s	180 s	仅缓慢追踪长期漂移
平滑时间常数 <code>smooth_tau_s</code>	2.0 s	2.0 s	EMA 抑制噪声
响应反推时间常数 <code>response_tau_s</code>	2.0 s	2.0 s	支持构造输入估计特征
趋势窗口 <code>trend_window</code>	8	8	估计短时间变化方向
归一化尺度 <code>scale</code>	0.35	1500 ADC（待复标定）	对齐各自信号域量级
裁剪幅度 <code>clip</code>	5	5	限制异常值对网络输入的影响

2.4 硬件电路与接口

当前下位机以 STM32F103C8T6 为核心。两路舵机 PWM 建议使用 TIM2_CH1/CH2，对应 PA0/PA1；两路 MQ-3 模拟量通过 ADC1_IN2/IN3 接入 PA2/PA3；USART1 使用 PA9/PA10 与上位机通信。硬件配置中串口默认 115200 bit/s，两路 MQ-3 每次读数可进行多次 ADC 采样平均。需要特别注意，STM32F103 的 ADC 输入不得超过 3.3 V，而常见 MQ-3 模块使用 5 V 供电，其 AO 电压上限可能高于 3.3 V，因此真机必须通过量程验证、分压或保护电路保证 ADC 安全。

MQ-3 主要面向酒精/乙醇类气体，且存在交叉敏感性。因而本文原型实验只能证明所用传感器—目标气体组合下的主动采样可行性，不能直接外推到有毒气体或可燃气体检测；面向其他气体时应更换匹配的传感器并重新完成标定、预处理尺度和安全设计。

表2-2 当前 STM32 外设分配

功能	资源/接口	说明
左触须舵机	PA0 / TIM2_CH1	PWM 输出
右触须舵机	PA1 / TIM2_CH2	PWM 输出，安装方向可反向映射
左 MQ-3	PA2 / ADC1_IN2	模拟量采集
右 MQ-3	PA3 / ADC1_IN3	模拟量采集
串口发送	PA9 / USART1_TX	向上位机返回采样结果
串口接收	PA10 / USART1_RX	接收 STEP 扇区命令

2.5 嵌入式控制流程

下位机完成“命令解析—角度映射—PWM 执行—ADC 采样—数据返回”的闭环。上位机发送例如 STEP 3 7 的指令，分别表示左触须选择第3扇区、右触须选择第7扇区；STM32 将扇区中心角映射为舵机 PWM 脉宽，等待执行机构稳定后读取两路 ADC，并返回包含 left_sector、right_sector、left_adc 与 right_adc 的结构化数据。该协议使策略输出的离散扇区可以直接对应真机动作。

从论文方法完整性的角度，后续硬件实验应进一步标定左右舵机的实际角度范围、机械零位、死区和重复定位误差，并记录“命令发出到传感器采样”的总延迟。上述参数可反向写入仿真中的舵机速度限制、采样周期和传感器时间常数，形成更严格的 sim-to-real 参数闭环。

2.6 仿真—真机观测语义一致性

本项目在软件结构上让仿真环境与硬件 rollout 复用同一套预处理逻辑和同一组触须几何特征，但“语义一致”不等于“数值分布已经一致”：仿真浓度域与真实 ADC 域使用不同归一化尺度，传感器时间常数和噪声也仍需实测校正。策略看到的不是仿真内部瞬时真实浓度，而是经过慢响应传感器与在线预处理后得到的相对量；策略也看不到真实风向和真实气源坐标。移动策略额外需要航向和上一移动动作，其中上一动作可由控制日志直接获得，航向需由编码器或 IMU 接口重建。该设计为复用网络接口创造条件，但能否直接迁移模型参数仍须通过观测分布对齐和真机闭环实验验证。

3 双触须主动采样与强化学习搜索算法

3.1 部分可观测决策建模

由于智能体无法观测完整羽流状态、瞬时风场和真实气源位置，同时气体传感器输出还具有内部动态记忆，因此更准确地说，本任务属于部分可观测马尔可夫决策过程。记隐藏环境状态为 s_t ，其中包含机器人真实位姿、气源位置、全部 puff 状态、风场状态以及传感器内部状态；智能体实际获得观测 $o_t = \Omega(s_t)$ ，并依据有限历史 $H_t = (o_{t-H+1}, \dots, o_t)$ 选择动作 a_t 。目标是学习参数化策略 $\pi_\theta(a_t | H_t)$ ，最大化折扣累积回报：

$$J(\theta) = E_{\pi_\theta} [\sum_{t=0}^{\infty} \gamma^t r_t]$$

其中 γ 为折扣因子，当前 PPO 训练使用 $\gamma=0.99$ 。这里用历史窗口而非单帧观测的原因并不是简单增加输入维度，而是用有限记忆逼近 POMDP 的 belief/state summary：传感器趋势、近期气味命中和触须位置变化共同帮助网络判断当前处于“进入羽流”“离开羽流”“长时间失嗅”或“刚刚重捕获”等不同阶段。

3.1.1 固定基座主动采样任务

固定基座任务用于回答主动触须是否增加信息获取这一核心假设。机器人位姿保持不变，动作仅为左右触须扇区 $a_t = (a_t^L, a_t^R) \in \{0, \dots, 9\}^2$ ；环境不设置“到达气源”终止目标。主比较对象为多个固定扇区、周期扫描、随机邻域扫描以及学习型主动策略。评价以传感器命中、趋势、左右差分、失嗅后重捕获和采样动作代价为主。该任务减少了底盘运动造成的采样位置变化和羽流扰动，使触须控制方式成为主要实验变量。

3.1.2 移动机器人联合搜索任务

移动任务用于检验固定基座阶段观察到的信息增益能否转化为下游找源性能。动作扩展为底盘移动、左扇区和右扇区三部分，任务目标为从下风侧初始状态进入气源邻域。两级任务共享触须几何、传感器动态和预处理语义，但奖励与评价目标不同：固定基座任务验证信息获取，移动任务验证任务完成。论文不以移动任务的总回报单独证明主动触须有效。

3.2 动态羽流与嗅觉采样模型

环境采用动态 puff 羽流而非静态浓度函数。气源以离散气味团形式持续释放物质，每个 puff 具有中心位置 $\mu_i(t)$ 、质量 $m_i(t)$ 以及沿风向/横风向的扩散尺度 $\sigma_{\parallel,i}(t)$ 、 $\sigma_{\perp,i}(t)$ 。在局部风向坐标系中，第 i 个 puff 对位置 p 的浓度贡献可写为二维各向异性高斯近似：

$$C_i(p, t) = ((m_i(t)) / (2\pi\sigma_{\parallel,i}(t)\sigma_{\perp,i}(t))) \exp[-((1)/(2))(((\xi_i^2)/(\sigma_{\parallel,i}^2)) + ((\eta_i^2)/(\sigma_{\perp,i}^2)))]$$

其中 ξ_i 与 η_i 分别是采样点相对 puff 中心在顺风 and 横风方向上的坐标。总浓度为所有有效 puff 的叠加，再加入背景浓度和可选测量噪声：

$$C(p, t) = C_{bg} + \sum_i C_i(p, t) + \varepsilon_t$$

puff 中心随平均风输运，同时叠加具有时间相关性的随机速度扰动；扩散尺度随时间增大，质量随时间衰减，超过最大寿命或质量阈值的 puff 被移除。平均风向本身通过均值回复随机过程缓慢蜿蜒，使固定采样点出现气味命中与空白交替。与平滑高斯羽流相比，这种环境更适合研究主动采样，因为触须扇区改变会真实改变碰到稀疏气味条带的概率。

移动环境进一步在每个 episode 随机化平均风向、源位置、机器人下风侧初始位置和初始朝向。当前搜索区域为边长约 2 m 的正方形（坐标约为 ± 1 m），episode 最大 400 步；移动环境默认风速范围为 0.12–0.20 m/s，并延长 puff 最大寿命，使羽流能够跨越较大搜索区域。

3.3 差速机器人运动模型

机器人采用六动作离散近似：前进、左转前进、右转前进、原地左旋、原地右旋和停止。为避免与价值函数符号 v_π 混淆，记线速度为 u 、角速度为 ω 、步长为 Δt ，前进动作可写为：

$$x_{t+1}=x_t+u\Delta t\cos\psi_t, y_{t+1}=y_t+u\Delta t\sin\psi_t, \psi_{t+1}=\psi_t$$

左/右转动作先改变航向 $\pm\omega\Delta t$ ，再以 $0.5u\Delta t$ 的距离沿新航向移动；原地旋转只改变航向；停止动作保持位姿不变。当前移动环境默认 $u=0.15$ m/s、 $\omega=1.5$ rad/s、 $\Delta t=0.2$ s，因此一次完整前进约移动 0.03 m，一次旋转约改变 0.30 rad（约 17°）。这种离散动作既降低策略输出维度，又容易映射到底盘速度指令。

3.4 非对称气体传感器动态

为了避免策略直接使用瞬时真实浓度，仿真在触须采样点浓度之后加入气体传感器动态。当前硬件导向环境默认使用非对称一阶模型：当输入浓度高于内部状态时采用较快响应时间常数 τ_r ，当输入下降时采用较慢恢复时间常数 τ_f 。令 y_t 为传感器内部干净状态，目标浓度为 c_t ，则：

$$\alpha_t=\exp(-((\Delta t)/(\tau_t))), \tau_t=\tau_r, c_t\geq y_{t-1}; \tau_t=\tau_f, c_t<y_{t-1}.$$

$$y_t=\alpha_t y_{t-1}+(1-\alpha_t)c_t$$

当前默认 $\tau_r=0.6$ s、 $\tau_f=3.0$ s，体现“响应快、恢复慢”的特征，并可加入高斯测量噪声和缓慢 OU 基线漂移。由于策略输入还要经过第2章所述在线基线与平滑处理，因此整体观测链条为“动态羽流真实浓度 → 传感器物理滞后/噪声 → 在线预处理 → 强化学习观测”。这比直接把 $C(p,t)$ 输入网络更接近真实硬件。

3.5 观测状态设计

当前移动搜索策略默认使用 16 维单帧硬件可重建观测。前 12 维来自双气体传感器与触须几何，后 4 维为移动机器人本体与搜索阶段信息。其中气体与触须特征已接入现有 STM32/上位机链路，航向仍需由移动底盘编码器或 IMU 提供；因此“可重建”表示不存在仿真特权量，不表示完整移动真机接口已经完成。各维定义如下。

表3-1 默认 16 维单帧观测

序号	观测量	物理含义
1-2	left/right_norm_signal	左右通道相对基线的归一化瞬时信号
3-4	left/right_norm_smooth	左右通道 EMA 平滑信号
5-6	left/right_norm_trend	左右通道短时变化趋势
7	norm_smooth_diff	左右平滑信号差，提供侧向对比信息
8	norm_trend_diff	左右趋势差，提供变化方向对比
9-10	left/right_angle_norm	左右触须当前实际相对角度归一化
11-12	left/right_sector_norm	左右目标/离散扇区归一化
13-14	heading_cos / heading_sin	机器人自身航向的周期连续表示
15	last_move_norm	上一时刻移动动作的归一化编码
16	blank_age_norm	失去气味后的持续时间，裁剪并归一化

这一设计遵循“可部署性优先”原则。真实风向、真实气源方向、真实到源距离、每个 puff 的位置与瞬时真实浓度均不进入策略。训练时奖励可以访问真实距离用于塑形，因此不会造成推理阶段的输入缺失，但会降低“行为完全由嗅觉学习而来”这一因果解释的强度。正式实验需把无距离塑形 ($k_d=0$) 作为关键消融，并将默认距离塑形结果表述为训练辅助条件。

航向使用 $\cos\psi$ 和 $\sin\psi$ ，而不是直接输入 ψ ，是为了避免 $-\pi$ 与 $+\pi$ 在数值上相距很远但物理方向几乎相同的边界不连续问题。blank age 则显式向策略提供“已经多久没有闻到气味”的阶段信息，使策略有可能学习从追踪状态切换到重捕获/探索状态。

3.6 联合动作空间设计

策略动作定义为三元组：

$$a_t = (a_t^m, a_t^L, a_t^R) \in \{0, \dots, 5\} \times \{0, \dots, 9\} \times \{0, \dots, 9\}$$

其中 a_t^m 为 6 类底盘移动动作， a_t^L 与 a_t^R 分别为左、右触须扇区。若把所有组合完全展开，共有 $6 \times 10 \times 10 = 600$ 种联合组合，但实现中使用 `MultiDiscrete([6,10,10])`，而不是建立一个 600 类单一离散动作。PPO 的 `MultiCategorical` 策略对三部分输出分别产生分类分布，在共享状态表示条件下其联合概率可写为：

$$\pi_\theta(a_t | H_t) = \pi_\theta^m(a_t^m | H_t) \pi_\theta^L(a_t^L | H_t) \pi_\theta^R(a_t^R | H_t)$$

因此，网络最后只需要输出 $6+10+10=26$ 个 logits，再按三组进行 softmax。该因子化既保留左右触须的独立选择能力，又避免直接对 600 个组合输出分类概率所带来的参数冗余。需要指出的是，三类动作并非物理独立：它们共享同一时序状态表征，并通过共同回报联合训练，所以策略仍能够学习“某种本体动作应配合某种触须姿态”的协同关系。

3.7 历史窗口与时序数据特征提取

气体传感器滞后和羽流 whiff/blank 结构使单帧状态不足以描述搜索过程。训练脚本使用长度 H 的固定历史窗口，将最近 H 帧观测按时间顺序堆叠。当前默认 $H=20$ ；以环境步长 0.2 s 计，相当于包含约 4 s 的环境历史，而传感器恢复时间常数约 3 s ，因此该窗口至少覆盖一个显著的恢复时间尺度。环境接口仍保持一维 Box，历史在包装器中扁平化为 $H \times d_o$ 维向量，进入特征提取器后再恢复为 $[\text{batch}, H, d_o]$ 。

3.7.1 MLP 历史基线

最简单的基线直接把 H 帧观测连接成一个长向量并输入 MLP。它能够利用窗口中的全部数值，但缺乏显式的时间结构归纳偏置：不同时间位置仅由输入神经元位置隐式区分。因此，MLP 适合作为“是否真的需要时序模型”的消融基线。

3.7.2 GRU 时序编码器

当前训练脚本默认使用门控循环单元（Gated Recurrent Unit, GRU）编码历史[14]。对第 $t-H+1$ 至 t 帧输入 x_k ，GRU 通过更新门 z_k 、重置门 r_k 和候选状态 $\tilde{h}_k$ 递归更新隐藏状态：

$$\begin{aligned} z_k &= \sigma(W_{zxk} + U_{zhk-1} + b_z), r_k = \sigma(W_{rxk} + U_{rhk-1} + b_r) \\ \tilde{h}_k &= \tanh(W_{hxx} + U_h(r_k \odot h_{k-1}) + b_h) \\ h_k &= (1 - z_k) \odot h_{k-1} + z_k \odot \tilde{h}_k \end{aligned}$$

最终取最后一层 GRU 的末时刻隐藏状态 h_t ，经线性层和 GELU 得到 64 维特征 f_t 。当前默认 `hidden_size=64`、层数为1。GRU 的优势是参数量较小、递归结构天然强调时间顺序，对于低维、强自相关、慢变化的气体传感器序列具有较合适的归纳偏置；同时相比 Transformer，PPO 在相同交互样本量下更容易获得稳定梯度。

3.7.3 Transformer 时序编码器

Transformer 版本[4]首先将每帧 16 维观测线性投影到 $d_{\text{model}}=64$ ，并依次经过 GELU 与 LayerNorm：

$$e_k = \text{LayerNorm}(\text{GELU}(W_{\text{exk}} + b_e))$$

随后在序列首部加入可学习的 [CLS] token，并叠加可学习位置编码。编码器默认使用2层、4头自注意力、前馈隐藏维128、dropout=0.1。第 l 层多头自注意力的基本形式为：

$$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

编码完成后取 [CLS] 对应输出，经线性投影得到 64 维特征 f_t 。与 GRU 相比，Transformer 能够直接建模窗口内任意两个时刻之间的关系，并允许离线导出每层、每个注意力头中 [CLS] 对历史时间步的注意力权重，从而分析策略究竟更关注“最近一次气味命中”“触须切换前后”还是其他历史阶段。其代价是模型复杂度和样本需求更高，因此本文把 Transformer 作为重要对比和可解释性工具，而不是预设它一定优于 GRU。

3.8 Actor-Critic 网络结构

经 MLP/GRU/Transformer 获得时序特征 f_t 后，PPO 使用 Actor-Critic 结构同时学习策略和状态价值[1,3]。当前策略配置共享同一个时序特征提取器，之后 Actor 与 Critic 进入各自的两层全连接网络，每层 160 个隐藏单元。Actor 最终输出 26 个 logits，分别对应移动6类、左触须10类和右触须10类；Critic 输出单个标量 $v_\varphi(H_t)$ 。从硬件可重建观测历史到策略与价值输出的完整信息流如图3-1所示。




图3-1 双触须主动嗅觉 PPO 的时序 Actor-Critic 网络架构。长度为 $H=20$ 的观测历史由每帧 16 维硬件可重建特征组成，不包含真实风向、气源位置或到源距离。历史编码器可在扁平 MLP、GRU 和 Transformer 之间切换，当前默认 GRU 将序列压缩为 64 维共享特征 f_t ；Actor 与 Critic 随后分别经过两层 160 单元全连接网络。Actor 的 26 个 logits 被拆分为移动 6 类、左触须 10 类和右触须 10 类三个分类分布，Critic 输出状态价值 $v_\varphi(H_t)$ 。琥珀色虚线路径表示 rollout、GAE 与 PPO 联合目标对共享编码器及两条分支的训练期梯度更新，不属于部署时的前向推理路径。

$$f_t = F_\omega(o_{t-H+1:t})$$

$$\ell_t^\pi = g_\theta(f_t) \in \mathbb{R}^{26}, v_\varphi(H_t) = g_\varphi(f_t) \in \mathbb{R}$$

价值函数 $v_\varphi(H_t)$ 表示从当前观测历史出发、继续按当前策略行动时的期望折扣回报。它并不直接决定动作，而用于构造低方差优势估计并训练 Critic。Actor 则根据优势方向提高“比当前平均水平更好”的动作概率、降低较差动作概率。共享时序特征提取器使嗅觉历史表示同时接受策略损失和价值损失的梯度约束。

3.9 PPO 算法的理论推导：从策略梯度到近端更新

PPO 并不是一个孤立提出的经验目标，而是沿着“直接优化期望回报—降低梯度估计方差—限制单次策略变化”这条逻辑链逐步得到的。为与本文的 POMDP 建模一致，以下用观测历史 H_t 代替完全可观测状态 s_t 。若历史编码器能够保留决策所需信息，则后续推导与标准 MDP 中以状态为条件的推导形式相同。策略梯度、GAE 与 PPO 的基本理论分别参考文献[1]—[3]。

3.9.1 从轨迹概率到策略梯度

设一条长度为 T 的交互轨迹为

$$\tau = (H_0, a_0, r_0, H_1, a_1, r_1, \dots, H_T),$$

其在参数化随机策略 π_θ 下的概率可分解为

$$p_\theta(\tau) = p(H_0) \prod_{t=0}^{T-1} \pi_\theta(a_t | H_t) p(H_{t+1} | H_t, a_t).$$

环境初始分布与转移规律不依赖策略参数 θ ，因此 θ 只出现在动作概率中。定义折扣轨迹回报

$$R(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t, J(\theta) = E_{\tau \sim p_\theta} [R(\tau)].$$

直接对 $J(\theta)$ 求导，并利用对数导数恒等式 $\text{grad}_\theta p_\theta = p_\theta \text{grad}_\theta \log p_\theta$ ，可得

$$\text{grad}_\theta J(\theta) = \int \text{grad}_\theta p_\theta(\tau) R(\tau) d\tau; = E_{\tau \sim p_\theta} [R(\tau) \text{grad}_\theta \log p_\theta(\tau)]; = E_{\tau \sim p_\theta} [R(\tau) \sum_{t=0}^{T-1} \text{grad}_{\log \pi_\theta}(a_t | H_t)].$$

动作 a_t 不可能影响 t 以前已经获得的奖励，因此可依据因果性去掉每个梯度项之前的奖励，只保留从当前时刻开始的 return-to-go。令

$$G_t = \sum_{l=0}^{T-t-1} \gamma^l r_{t+l},$$

则在折扣状态访问分布的记号下，策略梯度定理可以写为

$$\text{grad}_\theta J(\theta) \propto E_{H_t, a_t \sim \pi_\theta} [\text{grad}_{\log \pi_\theta}(a_t | H_t) q_{\pi_\theta}(H_t, a_t)],$$

其中

$$q_\pi(H_t, a_t) = E_\pi[G_t | H_t, a_t].$$

比例常数或外层的 γ^t 权重取决于采用有限时域目标还是归一化折扣访问分布，但不改变梯度上升方向。该结果给出 REINFORCE 形式的无偏 Monte Carlo 估计：

$$\hat{g}_{MC} = ((1)/(N)) \sum_{i=1}^N \sum_t \text{grad}_{\log \pi_\theta}(a_t^{(i)} | H_t^{(i)}) G_t^{(i)}.$$

它的直观含义是：若一次采样动作之后获得较大回报，就沿着提高该动作对数概率的方向更新；反之则降低其概率。但 G_t 同时包含动作效果、场景随机性、羽流随机性和后续动作随机性，因此方差通常很大。

3.9.2 基线为何能够降低方差而不引入偏差

可以从 $q_\pi(H_t, a_t)$ 中减去任意只依赖 H_t 、不依赖当前动作 a_t 的基线 $\beta(H_t)$ 。这是因为

$$E_{a_t \sim \pi_\theta} [\text{grad}_{\log \pi_\theta}(a_t | H_t) \beta(H_t)] = \beta(H_t) \sum_a \pi_\theta(a | H_t) \text{grad}_{\log \pi_\theta}(a | H_t) = \beta(H_t) \sum_a \text{grad}_{\log \pi_\theta}(a | H_t) \pi_\theta(a | H_t) = \beta(H_t) \text{grad}_{\log \pi_\theta}(\sum_a \pi_\theta(a | H_t)) = 0.$$

因此

$$E[\text{grad}_{\theta \log \pi_{\theta}}(a_t | H_t)_{\pi}(H_t, a_t) - \beta(H_t)]$$

与原策略梯度具有相同的期望。减去基线并不是改变优化目标，而是引入控制变量：把所有动作在同一历史状态下共同具有的“场景难易程度”抵消掉，使更新主要由动作相对平均水平的好坏决定。

最常用的基线是状态价值函数

$$v_{\pi}(H_t) = E_{a_t \sim \pi_{\theta}}[q_{\pi}(H_t, a_t)].$$

由此定义优势函数

$$A_{\pi}(H_t, a_t) = q_{\pi}(H_t, a_t) - v_{\pi}(H_t).$$

于是策略梯度写成

$$\text{grad}_{\theta} J(\theta) \propto E[\text{grad}_{\theta \log \pi_{\theta}}(a_t | H_t) A_{\pi}(H_t, a_t)].$$

当 $A_{\pi} > 0$ 时，该动作比当前策略在同一观测历史下的平均动作更好，应提高其概率；当 $A_{\pi} < 0$ 时，应降低其概率。这正是 Actor-Critic 的分工：Actor 表示 π_{θ} ，Critic 用 v_{φ} 近似 v_{π} ，再由 Critic 构造比原始回报方差更低的优势估计。需要注意，价值基线只能降低由“历史整体价值差异”造成的波动， v_{φ} 的估计误差仍会进入优势，因此还需要设计合适的时序估计器。

3.9.3 从 TD 残差到多步优势估计

若使用一步自举，价值函数的 TD 残差为

$$\delta_t = r_t + \gamma(1 - \iota_t)v_{\varphi}(H_{t+1}) - v_{\varphi}(H_t),$$

其中终止指示量 $\iota_t \in \{0, 1\}$ ； $\iota_t = 1$ 表示 t 步之后是真正终止状态，终止时不再自举。若只是因 rollout 长度截断而非环境终止，则仍应从 $v_{\varphi}(H_{t+1})$ 自举。当 $v_{\varphi} = v_{\pi}$ 时，

$$E[\delta_t | H_t, a_t] = A_{\pi}(H_t, a_t),$$

所以一步 TD 残差可以作为优势估计。它只包含一步随机奖励，方差较小，但强烈依赖 Critic 的准确性，因而可能产生较大偏差。

把连续 k 个 TD 残差按折扣相加，可利用中间价值项的望远镜消去得到 k 步优势估计：

$$A_t^{(k)} = \sum_{l=0}^{k-1} \gamma^l \delta_{t+l}; \quad = \sum_{l=0}^{k-1} \gamma^l r_{t+l} + \gamma^k v_{\varphi}(H_{t+k}) - v_{\varphi}(H_t).$$

当 $k=1$ 时是低方差、较高自举偏差的一步 TD；当 k 延伸到 episode 末端时，末端价值为零，它退化为 $G_t - v_{\varphi}(H_t)$ ，即低自举偏差、但高采样方差的 Monte Carlo 优势。由此可见，优势估计的核心矛盾是自举偏差与轨迹采样方差之间的权衡。

3.9.4 广义优势估计 GAE 的由来

对 $0 \leq \lambda < 1$ ，GAE 将所有 k 步优势估计按几何权重混合[2]； $\lambda=1$ 则由极限定义：

$$A_t^{\text{GAE}(\gamma, \lambda)} = (1 - \lambda) \sum_{k=1}^{\infty} \lambda^{k-1} A_t^{(k)}.$$

把上一节的 $A_t^{(k)}$ 代入并重新整理各 TD 残差的系数，可以得到更常用的等价形式：

$$A_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}.$$

有限 rollout 中使用反向递推实现：

$$A_t^{\wedge} = \delta_t + \gamma \lambda (1 - \iota_t) A_{t+1}^{\wedge}.$$

参数 $\lambda \in [0, 1]$ 控制偏差—方差折中：

- $\lambda=0$ 时, $A_t^{\wedge} = \delta_t$, 主要依赖一步自举, 方差小但对价值误差敏感;
- $\lambda \rightarrow 1$ 时, 估计逐渐接近完整 return-to-go 减去价值基线, 偏差通常减小而方差增大;
- 中间取值对远期 TD 残差施加指数衰减, 兼顾信用分配长度与训练稳定性。

本文采用 $\gamma=0.99, \lambda=0.95$ 。对于气味源搜索, 这意味着短时气味命中、重捕获和动作结果获得较大权重, 同时仍把若干步后的到源收益向前传播。用于训练 Critic 的回报目标为

$$R_t^{\wedge} = A_t^{\wedge} + v_{\varphi_{\text{old}}}(H_t),$$

并在优化时将该目标视为常量。这里的“优势加旧价值”来源于 $A_{\pi} = q_{\pi} - v_{\pi}$, 不是把动作价值与状态价值混为一谈, 而是在采样策略和旧 Critic 下重建一个低方差的价值回归目标。

3.9.5 从策略梯度到重要性采样代理目标

上述梯度要求样本来自当前策略。然而 PPO 会固定一批由旧策略 $\pi_{\theta_{\text{old}}}$ 收集的 rollout, 并对它进行多个 epoch 的 minibatch 更新; 参数第一次更新后, 数据分布就不再等于新策略分布。为在旧样本上评价新策略, 引入重要性采样概率比

$$\rho_t(\theta) = ((\pi_{\theta}(a_t | H_t)) / (\pi_{\theta_{\text{old}}}(a_t | H_t))) = \exp[\log \pi_{\theta}(a_t | H_t) - \log \pi_{\theta_{\text{old}}}(a_t | H_t)].$$

由于本文的移动、左触须与右触须动作采用条件因子化的 Multicategorical 分布,

$$\pi_{\theta}(a_t | H_t) = \prod_{j \in L, R} \pi_{\theta}^j(a_t^j | H_t),$$

故联合动作的对数概率与概率比分别满足

$$\begin{aligned} \log \pi_{\theta}(a_t | H_t) &= \sum_{j \in L, R} \log \pi_{\theta}^j(a_t^j | H_t), \\ \rho_t(\theta) &= \prod_{j \in L, R} ((\pi_{\theta}^j(a_t^j | H_t)) / (\pi_{\theta_{\text{old}}}^j(a_t^j | H_t))). \end{aligned}$$

在旧策略附近, 可优化的一阶代理目标为

$$L^{\text{PG}}(\theta) = E_t [\rho_t(\theta) A_t^{\wedge}].$$

当 $\theta = \theta_{\text{old}}$ 时 $\rho_t(\theta) = 1$, 该目标的梯度与采样时刻的策略梯度一致。概率比大于 1 表示新策略提高了已采样联合动作的概率, 小于 1 表示降低了它的概率。采用 ρ_t 而不是 r_t 表示概率比, 可避免与即时奖励 r_t 混淆。

3.9.6 为什么需要信赖域与 KL 散度

若对同一批数据反复、无约束地最大化 L^{PG} , 策略可能快速远离采样策略。此时会出现两类问题: 一是旧策略访问到的历史状态分布不再代表新策略的访问分布; 二是有限样本优势中的估计误差会被新策略过度利用。代理目标虽然在 θ_{old} 附近是一阶正确的, 但远离该点后不再可靠。

策略改进恒等式揭示了这一问题。对新旧两策略有

$$J(\pi_{\theta}) - J(\pi_{\theta_{\text{old}}}) = ((1)/(1-\gamma)) E_{H \square d_{\pi_{\theta}}, a \square \pi_{\theta}} [A_{\pi_{\theta_{\text{old}}}}(H, a)],$$

其中 $d_{\pi_{\theta}}$ 是新策略诱导的折扣访问分布。实际代理目标使用的是旧分布 $d_{\pi_{\theta_{\text{old}}}}$; 只有新旧策略足够接近时, 二者差异才可控。因此, TRPO 类方法在最大化代理目标的同时限制平均 KL 散度:

$$\max_{\theta} E_t[\rho_t(\theta)A_t^{\wedge}], \text{ s.t. } E_t[d_{\pi_{\theta_{old}}} [D_{KL}(\pi_{\theta_{old}}(\cdot|H_t) \setminus \pi_{\theta}(\cdot|H_t))] \leq \delta_{KL}.$$

离散动作分布的 KL 散度定义为

$$D_{KL}(\mu \setminus \nu) = \sum_a \mu(a) \log((\mu(a))/(\nu(a))) \geq 0.$$

它衡量用分布 ν 近似分布 μ 时增加的信息损失，具有非负性，但通常不满足对称性，即 $D_{KL}(\mu \setminus \nu) \neq D_{KL}(\nu \setminus \mu)$ 。本文监控的是旧策略到新策略的方向，因为 rollout 由旧策略采样。对因子化联合策略，条件 KL 可分解为三部分之和：

$$D_{KL}(\pi_{\theta_{old}} \setminus \pi_{\theta}) = \sum_{j \in L, R} D_{KL}(\pi_{\theta_{old}}^j \setminus \pi_{\theta}^j).$$

在旧参数附近，平均 KL 可作二阶近似

$$D_{KL}^{-} \approx ((1)/(2)) \Delta \theta^T F(\theta_{old}) \Delta \theta,$$

其中 F 是 Fisher 信息矩阵。代理目标作一阶近似为 $g^{\top} \Delta \theta$ ，从而得到自然梯度方向 $F^{-1}g$ 。TRPO 通过二阶近似、共轭梯度和线搜索近似求解约束问题，更新稳定但实现和计算相对复杂。PPO 的目标是在只使用一阶梯度优化的条件下，获得近似的“不要离旧策略太远”的效果[3]。

3.9.7 从 KL 惩罚到 PPO-Clip

一种直接做法是在代理目标中加入 KL 惩罚：

$$L^{KL PEN}(\theta) = E_t[\rho_t(\theta)A_t^{\wedge} - \kappa_{KL} D_{KL}(\pi_{\theta_{old}}(\cdot|H_t) \setminus \pi_{\theta}(\cdot|H_t))],$$

并根据实际 KL 是否超过目标值调节 κ_{KL} 。但固定惩罚系数对不同任务和训练阶段未必合适。PPO-Clip 改为直接构造逐样本的保守代理目标：

$$L^{CLIP}(\theta) = E_t[\min(\rho_t(\theta)A_t^{\wedge}, \text{clip}(\rho_t(\theta), 1-\epsilon, 1+\epsilon)A_t^{\wedge})].$$

其中 ϵ 为裁剪范围，本文取 $\epsilon=0.2$ 。该最小值对正、负优势产生不同的单侧限制：

$$\ell_t^{CLIP} = \min(\rho_t, 1+\epsilon)A_t^{\wedge}, A_t^{\wedge} \geq 0; [4pt] \max(\rho_t, 1-\epsilon)A_t^{\wedge}, A_t^{\wedge} < 0.$$

当 $A_t^{\wedge} > 0$ 时，算法希望提高该动作概率；但 $\rho_t > 1+\epsilon$ 后，目标被截在 $(1+\epsilon)A_t^{\wedge}$ ，继续提高概率不再获得额外收益。当 $A_t^{\wedge} < 0$ 时，算法希望降低该动作概率；但 $\rho_t < 1-\epsilon$ 后，目标被截在 $(1-\epsilon)A_t^{\wedge}$ ，继续降低概率也不再改善目标。取两项最小值使裁剪目标成为未裁剪代理收益的悲观估计，从而削弱过度更新的动力。

必须强调，PPO-Clip 并不是把所有概率比强制投影到 $[1-\epsilon, 1+\epsilon]$ ，也不等价于严格满足某个 KL 约束。裁剪只在“继续变化会让当前样本目标看起来更好”的方向上移除激励；共享网络参数、其他样本、价值损失和熵项仍可能使个别概率比越界。因此实践中仍需监控 KL 散度。本文设置 $target_{kl}=0.02$ ：若一个 rollout 上多轮更新造成的近似 KL 过大，则提前结束本轮 epoch，以同时使用“局部裁剪”和“整体分布漂移监控”两道稳定机制。

3.9.8 Actor、Critic 与熵正则的联合目标

PPO 的 Actor 最大化 L^{CLIP} 。Critic 以 GAE 构造的 $R_t^{\wedge}$ 为监督信号，最小化价值回归损失

$$L_v(\varphi) = ((1)/(2)) E_t[(v_{\varphi}(H_t) - R_t^{\wedge})^2].$$

为防止训练早期策略分布过快塌缩到少数动作，还加入策略熵

$$\text{Ent}[\pi_{\theta}(\cdot|H_t)] = -\sum_a \pi_{\theta}(a|H_t) \log \pi_{\theta}(a|H_t).$$

对本文的因子化动作分布，联合熵等于移动、左触须和右触须三个分类分布熵之和。以最小化形式表示，总损失为

$$L_{\text{total}} = -L^{\text{CLIP}} + c_v L_v - c_e E_t [\text{Ent}[\pi_\theta(\cdot | H_t)]].$$

其中 c_v 控制 Critic 回归权重， c_e 控制探索强度。本文设置 $c_e=0.003$ ，学习率为 1×10^{-4} 。每轮由 $N=8$ 个并行环境各采集 512 步，共得到 4096 个样本；数据划分为 256 大小的 minibatch，并最多重复优化 5 个 epoch。旧策略对数概率、旧价值与 GAE 目标在 rollout 结束后固定，当前网络则在每个 minibatch 上重新计算新对数概率、价值和熵。

综上，PPO 的完整逻辑链为：对期望回报使用对数导数得到策略梯度；用状态价值作为不改变期望梯度的基线形成优势函数；用 GAE 在 Monte Carlo 高方差与 TD 自举偏差之间折中；用重要性采样概率比复用旧策略 rollout；再用 Clip 抑制单样本上的过度概率变化，并以 KL 提前停止监控整体策略漂移。该链条共同解释了 PPO 为何能够在动态羽流、传感器滞后和联合离散动作带来的高噪声条件下保持相对稳定的更新。

3.10 奖励函数设计

奖励函数是本项目从“能够训练”走向“学习正确搜索行为”的关键。早期直觉式奖励容易把瞬时浓度、气味命中或左右差直接作为每步正奖励，但这种设计存在明显投机空间：机器人可能在一个局部高浓度点原地旋转、停止或重复扫描，从而持续获得正回报，而不需要真正接近气源。当前移动环境因此将奖励重构为七个分量。该奖励服务于移动找源训练；固定基座实验使用独立的信息指标评价，不能用下式的距离项或到源奖励比较扫描方式。

$$r_t = r_t^d + r_t^c + r_t^{\text{reacq}} + r_t^{\text{time}} + r_t^{\text{stag}} + r_t^{\text{goal}} + r_t^{\text{oob}}$$

3.10.1 距离差分奖励

设 d_{t-1} 和 d_t 为机器人中心到气源的距离，定义距离改善量 $\Delta d_t = d_{t-1} - d_t$ ，则：

$$r_t^d = k_d(d_{t-1} - d_t), k_d = 3.0$$

接近气源时该项为正，远离气源时为负，而原地保持为零。其累积在无终止扰动时具有近似望远镜求和性质，避免“只要在某个位置就持续得到距离奖励”。需要强调，真实距离只用于训练期 reward shaping 和评估，不输入策略网络，部署时不再需要该量。但“部署时不需要距离”与“训练没有使用特权监督”是两件不同的事；本文将同时报告 $k_d=3.0$ 与 $k_d=0$ 条件，只有后者才能更直接检验无距离塑形时的嗅觉驱动搜索能力。

3.10.2 历史最佳浓度增量奖励

令当前左右传感器输出最大值为 $c_t = \max(c_t^L, c_t^R)$ ，首先裁剪到 $[0, C_{\max}]$ ，并维护 episode 历史最佳值 $c_t^* = \max_{\tau \leq t} c_\tau$ 。只在当前读数刷新历史最佳时给予奖励：

$$\Delta c_t^* = \max[0, \text{clip}(c_t, 0, C_{\max}) - c_{t-1}^*]$$

$$r_t^c = k_{c\Delta} c_t^*, k_c = 3.0, C_{\max} = 1.0$$

这一设计的核心不是“奖励高浓度”，而是“奖励新的信息进展”。机器人即使停在高浓度区域，只要没有继续刷新历史最佳读数，就无法反复获取浓度正奖励。因此，该项从机制上抑制了原地保持高浓度刷分。

3.10.3 触须独立重捕获奖励

为了让主动触须本身具有可学习的价值，环境显式记录失嗅状态。若此前已经出现过气味命中，随后连续失嗅超过最短时间 $b_{\min}$ ，并在某一步重新命中，则定义一次 qualified reacquisition。根据最近一个 credit window 内是否发生底盘运动和触须运动，将重捕获进一步分为：底盘辅助重捕获、纯触须重捕获和被动重捕获。只有“近期无底盘运动、但触须发生运动并最终重捕获”的纯触须事件获得额外奖励：

$$r_t^{\text{reacq}} = k_{\text{reacq}} \text{ whisker-only reacquisition, ; 0, otherwise, } k_{\text{reacq}} = 0.25$$

当前每个 episode 最多奖励4次纯触须重捕获，最短失嗅时间为1.0 s，动作归因窗口为1.0 s。设置次数上限是为了防止策略故意反复制造“失嗅—重捕获”循环来刷取辅助奖励。该奖励既服务于性能，也为论文提供了可解释指标：可以单独统计纯触须、底盘辅助和被动重捕获占比，判断主动触须到底是否真正承担了信息恢复作用。

3.10.4 时间与停滞惩罚

每一步固定施加时间成本：

$$r_t^{\text{time}} = -0.03$$

从而使更短的搜索路径具有更高回报。环境还维护 stagnation counter：若一步既没有显著位移、没有历史最佳浓度提升、没有距离改善，也没有重捕获事件，则计数增加；达到20步后，在后续停滞步骤施加 -0.02 的额外惩罚。与直接惩罚“stop”动作不同，这种规则根据是否产生真实进展判断停滞，因此能够允许短暂停止采样，但不鼓励长时间无信息停留。

3.10.5 终止奖励与越界惩罚

当机器人进入气源半径 0.10 m 内，给予固定 +50 的到源奖励；越出搜索区域则给予 -25 的惩罚并终止。代码进一步进行奖励安全校验：所有正辅助奖励在理论上的总上界不得超过 goal bonus 的四分之一，同时越界惩罚必须覆盖整个 episode 的最大时间成本与全部正辅助奖励上界。这样可避免出现“提前越界反而比继续搜索更划算”或“辅助奖励总和压过真正到源目标”的奖励尺度错误。

表3-2 当前移动搜索奖励函数参数

奖励分量	当前默认系数/阈值	设计目的
距离差分	$k_d = 3.0$	持续提供接近/远离气源的有符号训练塑形
历史最佳浓度增量	$k_c = 3.0$, clip=1.0	只奖励刷新历史最佳，抑制高浓度停留刷分
纯触须重捕获	0.25, 最多4次/episode	强化主动采样在失嗅后的独立信息恢复
时间成本	-0.03/step	鼓励更快搜索
停滞成本	-0.02, 窗口20步	抑制长时间无位移/无信息进展
到源奖励	+50, 半径0.10 m	定义主要任务目标
越界惩罚	-25	抑制通过提前终止规避长期时间成本

3.11 一轮 PPO 训练的完整流程

结合上述环境与网络，一轮训练可按以下顺序理解：

1. 初始化 N 个随机场景环境。每个环境独立采样平均风向、气源位置、下风侧机器人初始位置和初始朝向，重置 puff、传感器动态、在线预处理器、触须状态以及 H 帧历史缓存。
2. 在每个环境步，历史窗口经 GRU/Transformer/MLP 编码为 f_t ；Actor 生成移动、左触须和右触须三个分类分布并采样联合动作；Critic 同时给出 $v_\phi(H_t)$ 。
3. 环境执行底盘动作与受速度限制的触须动作，推进动态羽流，在两个触须端点计算真实浓度并经过非对称传感器动态，再通过在线预处理得到下一帧硬件观测。
4. 环境根据真实到源距离差、历史最佳传感器读数变化、纯触须重捕获、时间/停滞/越界等因素计算奖励，并记录每个奖励分量和诊断信息。
5. 连续采集 $n_steps=512$ 后，将并行环境数据合并为 rollout buffer，利用保存的旧价值与奖励计算 TD 残差、GAE 优势和 value target。
6. 以 $batch_size=256$ 取 minibatch。对每个 minibatch 用当前网络重新计算动作 log probability、价值和熵，构造 PPO clipped actor loss、critic value loss 与 entropy regularization，反向传播更新共享时序特征提取器和 Actor/Critic 参数。
7. 对同一 rollout 数据重复 $n_epochs=5$ 轮；若近似 KL 超过 $target_kl=0.02$ ，则提前停止本轮策略更新。
8. 进入下一轮 rollout。训练过程中定期执行 deterministic evaluation、保存 checkpoint，并将 episode 回报、价值/策略损失、各奖励分量、blank 行为和重捕获类型写入 TensorBoard。

3.12 算法设计的关键逻辑

本章方法的核心并不是简单“把 PPO 用到气味源定位”，而是把三个容易混淆的问题分开处理：第一，动态 puff 与慢响应传感器造成的非马尔可夫观测由历史时序编码处理；第二，主动触须是否增加信息，先由固定基座对照和信息指标检验，再由移动任务验证下游转化；第三，强化学习常见的奖励投机由历史最佳增量、辅助奖励上界和越界安全约束抑制。纯触须重捕获奖励及其诊断只能表明奖励归因逻辑是否按设计运行，不能替代“主动策略优于固定/预设扫描”的对照实验。只有两级证据一致，最终性能变化才可以较谨慎地归因于主动采样，而不是距离塑形、网络差异或奖励漏洞。

4 仿真环境与参数优化

本章中的“优化”分为两类：一类是当前代码已经完成的结构性优化，例如把静态/连续浓度奖励改为历史最佳增量、把单帧观测改为硬件一致时序观测；另一类是需要通过正式多随机种子实验确定的数值超参数优化。为避免在尚无充分实验结果时倒推结论，本文第一版明确区分“当前默认值”和“最终论文最优值”。后续实验应在冻结测试场景和随机种子协议的前提下进行调参，不能在测试集上反复选择参数。

4.1 动态仿真环境搭建与物理参数

移动搜索环境建立在动态 puff 羽流之上，世界边界约为 $[-1,1] \times [-1,1] \text{ m}$ 。当前 step 顺序为先执行底盘动作，再推进羽流，随后按舵机速度约束更新触须并读取传感器；这一离散顺序是仿真实现约定，正式复现实验应保持不变。基础羽流使用稀疏、窄、有限寿命的气味团，配合横风向较强的时间相关湍流扰动和平均风向蜿蜒，目标是让固定位置产生明显 whiff/blank，而不是形成几乎连续的“气味墙”。只有在这种条件下，改变触须扇区才可能长期改变信息获取概率，主动采样才具有可检验空间。

本文不以“图像看起来像羽流”作为模型有效性的充分证据。冻结论文环境前，应在多个下风距离和横风偏移处报告间歇率、whiff/blank 时长分布和浓度分位数，并与真实实验或公开数据的量级进行对照。若修改 puff 尺度、寿命或域随机化范围，需重新运行同一诊断并重标定气味命中阈值和奖励尺度。

表4-1 动态羽流主要仿真参数（当前代码默认/移动环境覆盖值）

仿真量	当前移动环境/基础默认	说明
世界半宽	1.0 m	移动环境约 $2 \text{ m} \times 2 \text{ m}$
环境步长 Δt	0.2 s	统一机器人、羽流与传感器更新时间尺度
最大步数	400	超时结束 episode
风速范围	0.12–0.20 m/s	移动环境覆盖较大空间
puff 每步释放数	1（基础标称）	域随机化时可变
初始 puff 质量	0.012（标称）	带随机质量抖动
初始顺风/横风 σ	0.052 / 0.024 m	形成细长 filament
扩散率	0.008 / 0.003	顺风/横风尺度随时间增大
衰减率	0.052	puff 质量随时间衰减
最大 puff 寿命	16 s（移动环境覆盖）	保证羽流可到达下风侧起点
背景/噪声	0.005 / 0.004	浓度背景与随机扰动

场景随机化与物理随机化承担不同作用。前者改变任务几何：随机平均风向、源相对方位、机器人下风侧距离、横风偏移和初始航向，用于避免策略只记住固定地图方向。后者改变动力学分布：puff 释放数、质量、扩散、衰减、横风湍流强度、风向蜿蜒幅度、寿命以及传感器响应/恢复时间、噪声与基线漂移均可在标称值附近按 episode 随机化，用于增强对模型误差的鲁棒性。

4.2 域随机化策略

当前代码在开启 domain randomization 时，每个 episode 对羽流和传感器参数重新采样。例如 puff 初始质量约按标称值的 0.7–1.5 倍扰动，顺/横风扩散率和衰减率约按 0.7–1.4 倍扰动，风向蜿蜒幅度约按 0.6–1.4 倍扰动，puff 最大寿命约按 0.7–1.3 倍扰动；传感器响应时间约为标称值的 0.6–1.6 倍、恢复时间约为 0.6–1.8 倍，噪声幅值也随机变化，并可引入随机基线漂移。

域随机化不应在训练初期无条件开到最大范围。如果环境难度过大，策略可能在尚未掌握基础“趋源—重捕获”规律之前就面对过多分布变化，导致学习信号稀释。更合理的优化流程是先在 randomized geometry、nominal physics 下验证可学习性，再开启物理域随机化做鲁棒性微调，最后用完全独立的风向、起点与物理参数测试集评估泛化。

4.3 Actor-Critic 与时序模型参数优化

网络结构优化的首要原则是与输入统计特性和强化学习样本量匹配，而不是盲目增加模型规模。当前 16 维单帧观测和 $H=20$ 的历史窗口属于低维时序问题。GRU 的单层 64 维隐藏状态已经能够覆盖较长的传感器记忆；Transformer 使用 $d_{\text{model}}=64$ 、4 头、2 层和 128 维前馈层，规模同样被刻意限制。Actor/Critic 两个 MLP 分支均为 [160,160]。

表4-2 Actor-Critic 与 PPO 参数优化建议

参数	当前默认	建议正式实验候选
历史长度 H	20	10 / 20 / 40
时序编码	GRU	MLP / GRU / Transformer
GRU hidden	64	32 / 64 / 128
Transformer d_{model}	64	32 / 64 / 128
Transformer heads	4	2 / 4 / 8 (满足整除)
Transformer layers	2	1 / 2 / 3
Actor/Critic MLP	[160,160]	[128,128] / [160,160] / [256,256]
学习率	$1e-4$	$3e-5$ / $1e-4$ / $3e-4$
rollout n_steps	512	256 / 512 / 1024
batch size	256	128 / 256 / 512, 需与 rollout 整除约束一致
PPO epochs	5	3 / 5 / 10
entropy coef	0.003	0 / 0.001 / 0.003 / 0.01
target KL	0.02	0.01 / 0.02 / 0.03
优势标准化	开启 (SB3默认)	固定；若关闭需单独做尺度稳定性实验
value loss系数	0.5 (SB3默认)	0.25 / 0.5 / 1.0
梯度范数上限	0.5 (SB3默认)	0.3 / 0.5 / 1.0
优化器	Adam (SB3默认)	当前固定，不与网络结构同时调节

建议不要对所有参数进行全组合网格搜索。可以先固定 PPO 训练参数，仅比较 MLP/GRU/Transformer 和历史长度；确定时序编码后，再用少量候选测试学习率、熵系数与 rollout/batch 组合。每组至少使用多个独立训练 seed，并在同一组冻结评估场景上报告均值、标准差和置信区间。若仅比较单次最好曲线，很容易把 seed 偶然性误认为模型结构优势。

4.4 仿真训练的数据流与参数更新机制

前述参数表说明了训练“使用哪些数值”，本节进一步说明这些数值如何组成一次真正的优化更新。需要首先区分两类参数：第一类是神经网络可学习参数，包括时序特征提取器参数 ω 、Actor 参数 θ 和 Critic 参数 φ ，它们通过损失函数、自动微分与 Adam 优化器更新；第二类是羽流扩散率、传感器时间常数、奖励系数、历史长度和 PPO 超参数等实验参数。当前项目中的仿真环境不是可微分物理模型，第二类参数不会从策略损失中直接获得梯度，而是保持固定、按 episode 随机化，或在多组独立训练实验之间由外层调参协议选择。所谓“通过仿真训练优化参数”，在单次训练内部特指更新 $(\omega, \theta, \varphi)$ ，在多次实验之间才指选择环境、奖励和算法超参数。

4.4.1 从动态羽流到 rollout buffer 的数据流

当前移动搜索训练脚本使用 Stable-Baselines3 的 PPO 实现[6]，并通过 DummyVecEnv 同时维护8个独立环境。第 i 个训练环境使用 $\text{seed}+i$ ，评估环境使用 $\text{seed}+100000$ ，从而把训练采样和确定性评估分开。每个环境中的一条数据链如下：

场景与域参数采样 → 机器人、羽流和触须状态推进 → 双触须端点真实浓度 → 非对称慢响应传感器 → 在线基线/EMA/趋势/差分预处理 → 16维单帧观测 → 20帧历史堆叠 → 时序编码器 → Actor/Critic → 联合动作与状态价值 → 环境奖励及下一观测。

环境执行一步动作时，首先解码 $[a_t^m, a_t^L, a_t^R]$ ，推进差速机器人位姿和动态 puff 羽流，再根据受速度限制后的左右触须位置计算原始浓度。原始浓度经响应快、恢复慢的传感器模型得到 c_t^L, c_t^R ，随后由与硬件端共用的 WhiskerObservationBuilder 生成12维嗅觉与触须几何特征，再拼接航向 $\cos\psi_t, \sin\psi_t$ 、上一移动动作和归一化 blank age，形成16维 o_t 。这一顺序意味着策略看不到生成奖励所用的真实气源距离、真实风向或 puff 内部状态；这些仿真特权重只留在环境端计算奖励和评估指标。

ObservationHistoryWrapper 将最近 $H=20$ 帧按从旧到新的顺序连接，得到观测历史 $H_t=(o_{t-H+1}, \dots, o_t)$ 。因此，每个环境返回给 PPO 的输入维数为

$$d_{in}=H d_o=20 \times 16=320.$$

episode 重置时用第一帧观测填满整个历史队列，后续每一步丢弃最旧帧并加入新帧。将 H_t 在 minibatch 中恢复时间维后的张量记为 X_t ，则默认 GRU 提取器的输入为

$$X_t \in \mathbb{R}^{B \times 20 \times 16},$$

经单层、隐藏维64的 GRU 后取最后一层最终隐状态，再通过 Linear+GELU 得到64维时序特征 f_t 。share_features_extractor=True 表示同一个 $f_t=F_\omega(X_t)$ 同时送入 Actor 和 Critic；之后二者分别经过 [160,160] 的全连接分支，并沿用 SB3 MlpPolicy 默认的 Tanh 激活。Actor 产生26个 logits，对应移动6类、左触须10类和右触须10类，Critic 输出标量 $v_\phi(H_t)$ 。

表4-3 单个训练样本在项目中的主要数据形状

环节	张量/数据形状	内容
单帧环境观测	[16]	12维双传感器/触须特征 + 4维本体与失嗅信息
历史包装器输出	[320]	20帧按时间顺序连接
GRU输入	[B,20,16]	minibatch内恢复时间维
共享时序特征	[B,64]	GRU末状态经线性投影和GELU
Actor logits	[B,26]	分割为6、10、10三个分类分布
Critic输出	[B,1]	历史状态价值估计
联合动作	[B,3]	移动、左扇区、右扇区

在 rollout 阶段，策略依据三个分类分布采样联合动作，并把以下数据写入 on-policy buffer：观测历史、动作、即时奖励、episode 边界标记、旧策略对该联合动作的对数概率 $\log\pi_{\theta_{old}}(a_t|H_t)$ 以及采样时的旧价值 $v_{\phi_{old}}(H_t)$ 。三个动作分量的联合对数概率是各分类对数概率之和。每个环境连续收集512步，8个环境合并后得到4096个时序样本；这些样本只服务于紧接着的一轮 PPO 更新，更新结束后即被新的 on-policy rollout 替换，而不是像 DQN 一样长期存入经验回放池。

4.4.2 从奖励序列生成优势与价值目标

rollout 结束后，算法沿时间反向计算 TD 残差。令 $l_t \in \{0,1\}$ 表示真实终止指示量，则

$$\delta_t = r_t + \gamma(1-l_t)v_{\phi_{old}}(H_{t+1}) - v_{\phi_{old}}(H_t).$$

当前项目固定 $\gamma=0.99$ 、 $\lambda=0.95$ ，采用 GAE 递推

$$\hat{A}_t = \delta_t + \gamma\lambda(1-l_t)\hat{A}_{t+1},$$

并构造 Critic 的监督目标

$$\hat{R}_t = \hat{A}_t + v_{\phi_{old}}(H_t).$$

这里的奖励 r_t 已经是距离差分、历史最佳浓度增量、纯触须重捕获、时间成本、停滞惩罚、到源奖励和越界惩罚七项之和。因此，任一奖励分量都会先改变 r_t ，再通过 GAE 向此前若干动作传播，最终同时影响 Actor 的优势方向和 Critic 的回归目标。奖励系数虽然不接受梯度更新，却会直接缩放和改变网络收到的训练信号；这也是奖励优化不能只看总回报、而必须同时检查各分量与行为指标的原因。

SB3 默认在每个 minibatch 内对优势进行标准化：

$$\tilde{A}_t = ((\hat{A}_t - \mu_{\hat{A}})/(\sigma_{\hat{A}} + 10^{-8})).$$

标准化不会改变同一批样本中优势的相对次序，却能降低奖励尺度变化对梯度幅值的直接影响。它不能修复奖励目标错误；如果奖励鼓励原地旋转，标准化后仍会沿着错误行为方向更新。

4.4.3 minibatch 前向计算与三类误差函数

4096个样本被打乱后按 `batch_size=256` 划分，因此每个 epoch 有16个 minibatch。对一个 minibatch，当前网络重新计算新策略对已采样动作的对数概率、当前价值和策略熵：

$$(\log \pi_{\theta}(a_t | H_t), v_{\phi}(H_t), \text{Ent}_t) = \text{EvaluateActions}(X_t, a_t).$$

由新旧对数概率得到联合动作概率比

$$\rho_t(\theta) = \exp[\log \pi_{\theta}(a_t | H_t) - \log \pi_{\theta_{old}}(a_t | H_t)].$$

Actor 使用 PPO-Clip 的策略误差。由于训练代码执行梯度下降，实际最小化的是最大化目标的相反数：

$$L_{\pi} = -E_t[\min(\rho_t(\theta)\tilde{A}_t, \text{clip}(\rho_t(\theta), 0.8, 1.2)\tilde{A}_t)].$$

当更新方向试图把有利动作的概率提高到裁剪区间之外，或把不利动作的概率降低到区间之外时，裁剪分支在该方向不再提供额外改进梯度，从而抑制一次更新过大。Critic 使用 GAE 回报目标的均方误差：

$$L_v = E_t[(v_{\phi}(H_t) - \hat{R}_t)^2].$$

训练脚本没有设置 `clip_range_vf`，因此当前实现使用 SB3 默认的“不裁剪价值预测”方式。策略熵误差写为

$$L_{ent} = -E_t[\text{Ent}[\pi_{\theta}(\cdot | H_t)]].$$

熵越大， L_{ent} 越小；以正系数加入总误差后，梯度下降会保留一定随机探索。训练脚本未显式覆盖 `vf_coef`，因此采用 SB3 默认值0.5。结合项目显式设置的 `ent_coef=0.003`，实际总误差为

$$L_{\text{total}} = L_{\pi} + 0.5L_v + 0.003L_{\text{ent}}.$$

三项误差作用不同：策略误差决定哪些联合动作应更可能出现；价值误差提高 Critic 对未来折扣回报的预测精度，从而改善下一轮优势估计；熵误差延缓三个分类分布过早塌缩。只看 `train/loss` 的总和无法判断是哪一部分出了问题，因此项目同时记录 policy gradient loss、value loss、entropy loss、explained variance、approximate KL 和 clip fraction。

4.4.4 反向传播经过哪些网络参数

对每个 minibatch，SB3 先清空旧梯度，再由 PyTorch 对 L_{total} 执行反向传播。若把共享时序特征记为 $f_t = F_{\omega}(X_t)$ ，则链式法则给出

$$\text{grad}_{\omega} L_{\text{total}} = ((d L_{\text{total}})/(d f_t)) ((d f_t)/(d \omega)).$$

由于 GRU/Transformer 特征提取器由 Actor 与 Critic 共享， $d L_{\text{total}}/d f_t$ 同时包含策略误差、价值误差和熵误差的贡献。因此一次反向传播会沿两条主要路径返回共享编码器：

$$X_t \rightarrow F_{\omega} \rightarrow g_{\theta}^{\pi} \rightarrow \log \pi_{\theta}, \text{Ent} \rightarrow L_{\pi}, L_{\text{ent}}; g_{\phi}^v \rightarrow v_{\phi} \rightarrow L_v.$$

Actor 分支参数 θ 主要接收策略与熵梯度，Critic 分支参数 ϕ 接收价值梯度，而共享编码器参数 ω 接收三者的合成梯度。对 GRU 而言，误差从最终隐状态经 `Linear+GELU` 反传到20个时间步的门控递推参数；对 Transformer 而言，误差从 CLS 输出经两层自注意力、前馈网络、位置编码和帧投影反传。由此，时序模型不是预先固定的特征工程，而是与 PPO 目标共同端到端训练的可学习模块。

共享特征也带来梯度竞争：若价值误差远大于策略误差，编码器可能优先学习有利于回报拟合、却未必最有利于动作区分的表示；若价值误差长期很高，则其梯度噪声还会扰动 Actor。因此应结合 `train/value_loss` 和 `train/explained_variance` 判断 Critic 是否正在提供有效基线，而不能简单把更大的网络等同于更好的优化。

4.4.5 梯度裁剪与 Adam 参数更新

反向传播得到所有可学习参数的梯度后，当前脚本未覆盖 SB3 的 `max_grad_norm`，所以先按默认上限0.5进行全局梯度范数裁剪：

$$g \leftarrow g \cdot \min(1, ((0.5)/(||g||_2))).$$

梯度裁剪不改变正常的小梯度，只在动态羽流的稀有大额终止奖励、长时信用分配或 Transformer 不稳定造成梯度尖峰时限制单步更新幅度。随后由策略对象的默认 Adam 优化器更新 (ω, θ, ϕ) 。对任一参数向量 w ，Adam 的基本更新为

$$\begin{aligned} m_k &= \beta_{1mk-1} + (1 - \beta_1)g_k, \\ n_k &= \beta_{2nk-1} + (1 - \beta_2)g_k^2, \\ w_{k+1} &= w_k - \eta ((m_k^{\wedge})/(\sqrt{(n_k^{\wedge}) + \epsilon_{\text{Adam}})}), \end{aligned}$$

其中 $\eta = 10^{-4}$ 是当前学习率， $m_k^{\wedge}, n_k^{\wedge}$ 为偏差校正后的一、二阶矩估计。学习率决定整体步长，Adam 的二阶矩则按参数历史梯度尺度进行自适应缩放。这里将二阶矩记为 n_k ，以避免与价值函数 v_{π} 混淆。参数更新不穿过环境：环境输出的观测、奖励和终止信号在 rollout buffer 中均作为常量，反向传播只穿过当前 PyTorch 策略网络。

4.4.6 多轮样本复用、KL早停与下一轮采样

同一批4096个样本最多训练5个 epoch，即理论上最多执行

$$5 \times ((4096)/(256)) = 80$$

次 Adam 更新。样本复用提高了每次环境交互的利用率，但随着更新次数增加，新策略会逐渐偏离采样数据对应的旧策略。因此每个 minibatch 还计算

$$\Delta \log \pi_t = \log \pi_{\theta}(a_t | H_t) - \log \pi_{\theta_{old}}(a_t | H_t),$$

$$D_{KL}^{\wedge} = E_t [\exp(\Delta \log \pi_t) - 1 - \Delta \log \pi_t].$$

训练参数设置 `target_kl=0.02`。按当前 SB3 实现，当近似 KL 超过 $1.5 \times \text{target}_{kl}$ ，即约0.03时，会提前结束本轮 epoch，因而实际更新次数可能少于80次。`clip_range=0.2` 控制单样本代理目标，KL早停控制整批分布漂移，梯度范数裁剪控制参数空间中的瞬时步长，三者分别作用于不同层面。

完成最多5轮优化后，旧 rollout 被丢弃，更新后的策略重新与8个环境交互，生成新的数据分布。于是训练形成循环：

当前策略采样4096步 → GAE计算优势和回报目标 → 16个minibatch × 最多5轮 → 误差反向传播与Adam更新 → KL条件判断 → 新策略重新采样。

训练默认持续300000个全局环境步；每约2000步在独立评估环境中执行10个 deterministic episode，每约10000步保存 checkpoint。`run_metadata.json` 进一步保存训练 seed、各环境 seed、网络类型、输入维数、PPO参数、奖励参数和场景设置，使最终选出的模型能够追溯到对应的训练配置。

4.4.7 网络梯度优化与实验超参数优化的关系

一次训练运行只能回答“在给定环境和超参数下，网络权重能否通过梯度下降学到有效策略”。历史长度、编码器类型、学习率、熵系数、rollout长度、奖励尺度和域随机化范围仍需由外层实验比较。外层优化应把每一个候选配置视为完整训练任务，使用多个训练 seed，在冻结评估场景上比较成功率、路径效率、失嗅恢复和触须使用指标，再选择均值较高且方差较小的配置。

因此，第四章中的参数优化不是把所有变量放进同一个误差函数同时求导。更准确的两层结构是：内层使用 PPO 损失和反向传播优化 (ω, θ, φ)；外层使用多随机种子评估结果选择 H、网络结构、学习率、奖励系数和域随机化范围。把两层混为一谈会造成常见误解，例如认为羽流扩散率会被 Adam 自动学到，或仅凭训练损失下降就能断言某套环境参数更优。

4.5 奖励函数的优化逻辑

奖励优化应围绕“任务目标一致性”和“不可被局部策略反复套利”两项原则展开。对于气味搜索，最容易出现的错误是把“浓度高”“闻到气味”“左右差大”直接设为每步正奖励。它们虽然能够加速早期学习，却也会导致高浓度停留、原地旋转、触须快速抖动或反复制造重捕获事件。当前奖励通过以下四个层次控制这一问题。

1. 把绝对浓度改为历史最佳浓度增量：同一高浓度状态只能在首次刷新记录时产生正奖励。
2. 把到源趋势改为有符号距离差分：接近为正、远离为负、原地为零，避免固定位置持续得分。

3. 重捕获奖励只认定“无近期底盘运动、存在近期触须运动”的事件，并设置 episode 次数上限，避免通过本体旋转或故意失嗅套取奖励。
4. 对终止奖励和辅助奖励设置尺度约束，并计算越界惩罚最小安全值，确保最终优化目标仍然是到达气源。

正式优化时，建议首先固定 goal bonus=50 和安全约束，仅在有限范围内调节 k_d 、 k_c 、 k_{reacq} 、时间成本与停滞窗口。判断一个奖励版本是否更好，不能只看训练回报，因为回报本身正是被修改的目标。应同时看成功率、最终/最小到源距离、路径长度、stationary action ratio、blank body spin ratio 和 whisker-only reacquisition rate。若回报上升但成功率不升、stationary ratio 明显增加，通常意味着出现了新的奖励投机。

4.6 观测值的优化

观测优化经历了从“仿真容易学”向“真机可部署”转变的思路。对仿真而言，真实风向、相对气源方向和到源距离非常容易获取，输入这些量可以显著降低学习难度，但会改变研究问题本身：策略实际上在利用仿真 oracle，而不是从嗅觉信息推断方向。因此当前移动环境强制使用 hardware observation，策略只接收传感器与本体可得信息。

在硬件观测内部，进一步避免只输入原始 ADC。相对基线信号表达“是否偏离洁净空气”，EMA 表达稳健强度，trend 表达时间方向，左右差表达空间不对称，触须角度/扇区表达当前采样几何。机器人航向用于维持连续的自身参考系；上一移动动作让网络知道刚刚发生的本体运动；blank age 则用于区分短暂漏检和长期失嗅。最后再通过 H 帧历史把这些局部线索组合为时序状态。

建议的观测消融至少包括：去除 trend、去除左右差、去除触须角度/扇区、去除 blank age、单帧 H=1、privileged 上界。privileged 上界不用于主方法，而用于回答“性能瓶颈来自部分可观测还是优化困难”。如果 privileged 策略显著更强，说明信息不足仍是主要限制；如果两者接近，则说明硬件观测已经包含足够信息。

4.7 动作空间的优化

动作优化需要在表达能力与训练难度之间平衡。每侧10个扇区使触须拥有18°的离散角分辨率，同时总输出 logits 仅26个。若扇区过少，触须难以精细探测羽流边界；若扇区过多，动作熵增大、探索组合快速增加，并且真实舵机精度和稳定时间未必支持过细离散。因此10扇区是当前合理的中等分辨率起点，但仍应通过 5/10/15 扇区消融验证。

另一个关键优化是保留左右触须独立动作，而不是把两侧绑定为镜像扫描。独立动作允许出现一侧维持高信息方向、另一侧探索新方向的非对称策略，也允许策略根据羽流横向结构产生不同采样行为。与此同时，舵机速度约束让“动作变化频率”具有真实代价，即使奖励没有直接加入舵机能耗，过于频繁的大角度切换也无法瞬时实现。后续真机若发现机械寿命或能耗重要，可进一步在 reward 中加入角位移成本。

4.8 训练稳定性诊断

仅观察 rollout/ep_rew_mean 不足以判断 PPO 是否学到了正确行为。当前训练脚本已经把七类奖励分量分别统计到 TensorBoard，并额外记录失嗅阶段的行为诊断，包括 blank_body_spin_ratio、blank_body_motion_ratio、blank_whisker_motion_ratio、mean/max blank age、qualified reacquisition events、whisker-only/body-assisted/passive reacquisition 以及纯触须重捕获奖励次数。

这些曲线可以形成较明确的故障诊断逻辑。例如，若 ep_rew_mean 上升但 blank_body_spin_ratio 同时快速升高，说明策略可能通过原地旋转维持某类奖励；若 whisker_motion_ratio 很低且主动触须策略与固定触须基线接近，说明触须动作可能没有被有效使用；若 value loss 很高且 explained variance 长期接近零，则 Critic 难以拟合高方差回报，可检查奖励尺度、历史编码和 batch 设置；若 entropy 很快下降到极低，可能需要提高熵系数或降低学习率。

4.9 统一评估指标

正式评估应使用训练过程中从未用于调参的独立 seed/场景，并默认采用 deterministic policy。指标分为固定基座信息获取和移动找源两层：前者直接回答主动采样假设，后者回答信息增益是否转化为任务表现。当前 evaluation 模块覆盖移动任务的大部分指标，固定基座脚本另行输出命中、趋势、差分 and 重捕获指标。

表4-4 论文建议使用的核心评估指标

层级	类别	指标	解释
固定基座	气味接触	odor_hit_rate / high_information_rate	不移动底盘时获得有效气味信息的比例
固定基座	时空信息	mean_abs_trend_sum / mean_abs_smooth_diff	传感器变化与左右空间对比
固定基座	失嗅恢复	reacquisition_events / mean_reacquisition_time_s	失嗅后重新获得信号的能力
固定基座	动作代价	sector_switch_rate / angular_travel	信息收益对应的触须运动成本
移动找源	任务完成	success_rate	终止时是否进入 goal_radius
移动找源	效率	mean_steps / mean_path_length	成功或结束所需时间步与路径长度
移动找源	趋源能力	mean_final_distance / mean_min_distance / mean_net_progress	最终、最接近以及净接近程度
移动找源	气味接触	mean_odor_hits / plume_contact_ratio	策略与羽流接触程度
移动找源	失嗅恢复	mean_odor_loss_duration / mean_reacquisition_time	失去气味后的恢复效率
移动找源	行为稳定	stationary_action_ratio / blank_body_spin_ratio	是否存在停止/原地旋转型策略
移动找源	归因	whisker-only / body-assisted / passive reacquisition rate	重捕获究竟由触须、底盘还是自然羽流造成

其中气味命中由 $\max(c_t^L, c_t^R)$ 是否超过 hit threshold 判定；左右对比度定义为 $\text{mean}(|c_t^L - c_t^R|)$ ；路径长度由相邻机器人位置欧氏距离累加。相比只报告“平均奖励”，这些指标能够把搜索能力、信息获取和奖励投机区分开来。

4.10 建议的正式调参协议

为了使最终论文结果具有可重复性，建议按以下顺序完成参数优化：

1. 冻结环境版本和评估脚本，建立一组固定但不参与训练的测试 seeds；所有方法使用相同测试场景。
2. 先在固定基座环境比较多个固定角度、周期扫描、随机邻域扫描和主动策略；若主动方式不能改善预注册的信息指标，先修正采样几何、节奏或羽流条件，不急于用移动成功率包装结论。
3. 固定基座结果支持主动采样后，再用 GRU + 当前移动奖励跑 5 个训练 seeds，验证基础成功率和训练稳定性。
4. 固定奖励，只比较 H 与时序编码结构；选择平均表现高且方差较小的结构，而不是单次最高值。
5. 固定时序结构，再小范围优化学习率、熵系数、rollout/batch 和 PPO epoch；最后优化辅助奖励尺度，并同时监控反投机指标。
6. 对主移动方法增加 $k_d=0$ 的无距离塑形实验，并与 $k_d=3.0$ 分开解释；前者用于检验嗅觉驱动能力，后者用于评估训练辅助后的工程性能。
7. 在最佳 nominal 模型基础上开启 domain randomization 进行鲁棒性训练，分别报告 nominal test 和 randomized/shifted test；完成主方法后再做消融和 baseline，避免在每个 baseline 上使用不公平的额外调参预算。

5 实验设计与讨论

5.1 实验设置

正式实验围绕两条递进假设组织。H1：在固定基座和相同羽流序列下，学习型主动触须相对最佳固定角度与预设扫描获得更高的信息获取表现。H2：在相同底盘策略结构、训练预算和观测条件下，允许主动控制触须能够把 H1 的信息收益转化为更高的移动找源成功率或更短的失嗅时间。H1 是主动采样主张的直接证据，H2 是下游任务证据；如果 H1 不成立，即使 H2 的成功率提高，也不能优先归因于触须。

固定基座实验使用 [WhiskerOnlyPuffEnv](#) 或真实固定平台，移动实验使用 [MobileWhiskerPuffEnv](#)。训练阶段可使用8个并行环境、300k–1M 级别总交互步数作为起点，并依据学习曲线是否收敛决定最终预算；每种学习方法至少使用5个独立训练 seed。评估时采用共同随机数：同一组方法在相同的羽流、起点和物理参数 seeds 上测试，从而降低场景差异带来的方差。

统计推断以“训练 seed 的评估均值”为独立重复单位，而不是把同一模型运行的数百个 episode 当作彼此独立样本。对主要指标报告各训练 seed 的均值、标准差、95% 置信区间和相对效应量；若进行显著性检验，应预先指定主要指标并控制多重比较。对于固定基座的成对场景，可同时报告按场景配对差值。

【待补：最终训练总步数、训练 seed 数、每个 seed 的评估 episode 数、硬件/CPU/GPU 型号、Stable-Baselines3 与 PyTorch 版本。】

5.2 固定基座主动采样实验

固定基座实验是本文优先级最高的验证。机器人位置、朝向、两只传感器型号、预处理参数、采样周期和总实验时长保持一致，仅改变触须采样策略。至少比较以下方法：

- fixed-multi：固定在多个代表性扇区分别测试，不以单一角度代表“固定传感器”，最终同时报告最佳固定角度和固定角度平均值；
- periodic-scan：按 0→9→0 往返扫描，并报告每扇区停留时间；
- random-neighbor：每步只在相邻扇区内随机移动，作为满足舵机速度约束的无智能探索基线；
- active-PPO：由历史观测选择左右扇区的学习型主动策略。

仿真中所有方法使用相同羽流 seed 成对运行；真机中采用随机区组顺序交替执行不同方法，记录风扇设置、气源位置、气源强度、温湿度、传感器预热时间和基线策略，避免把羽流随时间漂移误认为方法差异。Best fixed 的角度只能在训练/验证场景上选择，随后冻结并在独立测试场景评估，不能直接从测试结果中挑选最佳角度。主要指标预先指定为 odor_hit_rate、high_information_rate 和 mean_reacquisition_time_s，趋势、左右差分、扇区覆盖与触须角位移作为次要指标。若主动方法只提高扇区熵而不提高命中、重捕获或趋势信息，则不能判定主动采样有效。由于部分信息指标也参与主动策略奖励，H1 只能证明策略优化了预定义的信息目标；这些目标是否具有任务价值仍需由 H2 的移动找源结果或其他下游估计任务验证。

表5-1 固定基座主动采样结果占位表

方法	Hit rate ↑	High-info ↑	Reacq time ↓	Trend ↑	Angle travel ↓
Active-PPO	【待补】	【待补】	【待补】	【待补】	【待补】
Best fixed	【待补】	【待补】	【待补】	【待补】	0
Mean fixed	【待补】	【待补】	【待补】	【待补】	0
Periodic scan	【待补】	【待补】	【待补】	【待补】	【待补】
Random-neighbor	【待补】	【待补】	【待补】	【待补】	【待补】

5.3 移动任务消融实验设计

消融实验的目标不是“把所有模块去掉一遍”，而是逐一回答论文中的因果问题。建议至少包含以下五组。

- Active whisker vs fixed/preset whisker：使用相同 PPO、时序编码、底盘动作、训练预算和奖励，只冻结或替换触须动作，检验主动触须本身的增益。
- Temporal encoder：MLP-History、GRU、Transformer，检验显式时序建模是否必要。
- No blank-age：移除失嗅持续时间，检验阶段变量对重捕获策略的作用。
- No whisker-reacquisition reward：保留主动触须动作但取消纯触须重捕获奖励，检验该辅助奖励是否真正促进信息获取而非仅改变总回报。
- No best-concentration shaping / naive odor reward：与历史最佳增量机制对比，重点观察 stationary/spin 等奖励投机指标。

- No domain randomization: 在 shifted physics 测试集上比较鲁棒性, 验证随机化对 sim-to-real 方向的价值。
- No distance shaping: 令 $k_d=0$, 检验策略在没有真实距离训练塑形时是否仍能依靠嗅觉完成搜索; 默认 $k_d=3.0$ 的结果作为工程训练条件单独报告。

表5-2 移动任务消融实验结果占位表

方法	Success ↑	Steps ↓	Path ↓	Odor loss ↓	Whisker-only reacq ↑	Stationary ↓
完整方法	【待补】	【待补】	【待补】	【待补】	【待补】	【待补】
-时序编码 (H=1)	【待补】	【待补】	【待补】	【待补】	【待补】	【待补】
-blank age	【待补】	【待补】	【待补】	【待补】	【待补】	【待补】
-纯触须重捕获奖励	【待补】	【待补】	【待补】	【待补】	【待补】	【待补】
固定触须	【待补】	【待补】	【待补】	【待补】	—	【待补】

5.4 与其他算法/采样策略的对比

当前仓库包含固定触须 DQN、联合 PPO 以及移动主动触须 PPO 的训练/评估入口, 但“固定触须 DQN vs 主动触须 PPO”同时改变了触须能力和强化学习算法, 不能作为主动触须的主因果对照。主比较应在移动环境中使用同一 PPO、同一时序编码、同一底盘动作与训练预算, 仅将触须动作替换为固定、多固定角度、周期扫描或随机扫描。DQN 或其他值函数方法可作为补充算法对照, 用于讨论算法选择, 而不适用于单独证明硬件结构优势。

完整对比建议包括: ①随机底盘 + 固定触须的下界; ②规则式 surge-cast 或横风/上风搜索; ③PPO 底盘 + 最佳固定触须; ④PPO 底盘 + 周期扫描; ⑤PPO 联合主动触须 (本文); ⑥使用真实风向或源方向的 privileged 上界。固定/扫描基线也应接收与其可执行动作一致的触须几何观测, 避免给某一方法额外信息。

还可在后续扩展双固定电子鼻和单电子鼻 baseline。此时应尽量保持传感器型号、传感器动态、底盘动作和训练预算一致, 仅改变采样点数量与是否可动, 以减少硬件结构与算法差异的混杂。

【待补: 正式对比结果与统计显著性检验。不要用 smoke training 或单次最好 seed 作为论文结论。】

5.5 预期分析维度与结果解释原则

即使最终主方法成功率显著提高, 也需要结合行为指标解释“为什么提高”。若主动触须方法同时表现为更短的 mean odor loss duration、更高的 whisker-only reacquisition rate、适度的 whisker motion ratio, 并且 stationary/spin 比例没有异常升高, 则可以更有力地说明触须正在主动获取信息。相反, 如果成功率提高但纯触须重捕获几乎为零, 则增益可能主要来自网络结构、奖励或其他训练差异, 不能简单归因于主动嗅觉。

Transformer 注意力分析可作为辅助解释, 而不应单独作为因果证据。可以对成功与失败 episode 中 [CLS] 对不同历史时间步的注意力进行平均, 重点标记最近气味命中、失嗅起点、触须大幅切换和重捕获时刻。如果若干注意力头在重捕获前稳定地关注较早的气味命中或趋势变化, 可作为模型利用时间记忆的定性证据; 但最终结论仍应以消融和任务指标为主。

5.6 方法优势

从当前系统设计看，本文方法具有四个相对清晰的特点。第一，主动触须把“采样位置”变成可学习动作，为同一底盘状态提供额外空间感知自由度。第二，策略观测从一开始就限制为硬件可重建量，减少仿真特权导致的部署落差。第三，时序编码显式针对慢响应气体传感器和间歇羽流，而不是把传感器当作无记忆的瞬时浓度计。第四，奖励函数和评估指标同时考虑奖励投机，使“高回报”与“真实完成找源任务”尽量保持一致，并能追踪主动触须到底贡献了什么。这些属于方法设计特点，是否形成性能优势仍以正式对照结果为准。

5.7 当前不足与局限

第一，当前动态 puff 模型仍然是二维简化模型，虽然包含输运、扩散、湍流扰动和风向蜿蜒，但无法替代真实三维流场或高保真 CFD；障碍物、机器人本体和触须运动对风场的反馈也未建模。第二，真实 MQ-3 的温湿度影响、器件间差异、长期老化、交叉敏感性和非线性标定尚未完全进入仿真，且本原型对酒精/乙醇类刺激的结论不能直接外推到其他危险气体。第三，训练奖励仍访问真实到源距离用于塑形，虽然该量不进入策略、部署时也不需要，但仍属于训练期 oracle；没有 $k_d=0$ 对照时，不能宣称策略完全由嗅觉学会趋源。第四，完整移动底盘硬件接口、航向估计和统一时间同步尚未闭环验证。第五，动作空间是离散扇区和离散底盘动作，对复杂真实底盘动力学的表达有限。第六，目前尚缺乏正式多随机种子结果和完整真机搜索实验，因此本初稿只能说明方法与实验方案，不能提前宣称性能提升。

5.8 后续真机实验建议

真机阶段建议先完成固定基座的采样方式对照，再验证观测分布一致性，最后测试闭环找源。固定基座实验需在同一天或随机区组内交替运行 fixed-multi、periodic、random-neighbor 和 active，避免按固定顺序测试导致气源挥发、风扇升温或传感器漂移与方法绑定。每轮记录原始 ADC、实际时间戳、扇区、舵机到位时间、温湿度和实验条件；基线更新策略在各组间保持一致。

随后比较仿真与真实预处理特征的分布、趋势窗口和响应/恢复曲线，据此更新 sensor_response_tau、sensor_recovery_tau、noise_std、baseline drift 和 preprocess scale。再运行策略但暂不控制底盘，检查动作频率、角位移和串口时序是否可执行。最后接入底盘、航向估计和统一时钟完成闭环搜索，并保留原始 ADC、预处理特征、动作概率、底盘里程计和成功判定日志，以便定位 sim-to-real 失败来自传感器、动力学还是策略。

6 结论与展望

本文围绕间歇羽流中的主动嗅觉采样与气味源搜索，建立了一套“固定基座信息获取验证 + 移动机器人下游找源验证”的双层研究框架。系统允许左右触须独立选择采样扇区，使传感器位置本身成为策略动作；算法使用不含真实风向、气源位置和到源距离的16维单帧观测与固定历史窗口，通过 GRU/Transformer/MLP 编码后接入 PPO Actor-Critic 网络，联合输出底盘和双触须动作。

针对强化学习容易出现的奖励投机问题，当前方法不对“高浓度状态”本身持续给奖，而只奖励历史最佳浓度提升；采用有符号到源距离差分提供训练塑形；只对满足动作归因条件的纯触须重捕获事件给有限次数奖励；同时加入时间、停滞和越界成本，并对辅助奖励总量与越界惩罚进行安

全尺度约束。仿真方面使用动态 puff 羽流、风向蜿蜒、小尺度湍流和非对称气体传感器动态，且支持场景与物理域随机化。

截至本文初稿，已完成触须硬件最小闭环、仿真环境、观测适配、训练入口和诊断指标，但尚未完成能够支撑性能结论的多随机种子训练、固定基座正式对照和移动真机闭环。因此，本文当前能够成立的结论是方法与验证协议已经形成，而不是主动触须已被证明优于固定传感器。

后续工作应首先在仿真和真机固定基座条件下，以多个固定角度、周期扫描和随机邻域扫描为对照，验证主动触须是否改善命中、趋势、左右差分或重捕获；随后在同 PPO、同训练预算的移动任务中检验其下游收益，并加入 $k_d=0$ 的无距离塑形对照。其次完成 MQ-3 标定、移动底盘航向接口和真实机器人闭环搜索，利用真机数据校正仿真参数。在证据链建立后，再引入障碍物风场、高保真羽流和视觉信息，扩展为多模态具身搜索问题。

附录A 当前代码关键参数汇总

表A-1 论文初稿对应的主要默认参数

模块	参数	当前值
移动环境	world_half	1.0 m
移动环境	max_steps	400
移动环境	goal_radius	0.10 m
底盘	forward_speed	0.15 m/s
底盘	turn_rate	1.5 rad/s
环境	dt	0.2 s
触须	length	0.15 m
触须	sector_count	10/侧
触须	servo_60deg_time	0.12 s
传感器	sensor_model	asymmetric
传感器	response/recovery tau	0.6 / 3.0 s
传感器	noise_std	0.006
仿真预处理	scale / dt_s	0.35 / 0.2 s
硬件预处理	scale (阶段暂定)	1500 ADC
观测	single-frame dim	16
观测	history length	20
时序	default encoder	GRU
GRU	hidden/layers/features	64 / 1 / 64
Transformer	d_model/heads/layers	64 / 4 / 2
Transformer	FF/dropout/features	128 / 0.1 / 64
PPO	learning rate	1e-4
PPO	n_envs × n_steps	8 × 512
PPO	batch / epochs	256 / 5

模块	参数	当前值
PPO	gamma / lambda	0.99 / 0.95
PPO	clip range / ent coef	0.2 / 0.003
PPO	target KL	0.02

附录B 论文内容与代码模块对应关系

表B-1 方法描述与仓库代码对应关系

论文内容	主要代码文件
固定基座主动采样环境	dual_whisker_rl/envs/whisker_only_env.py
固定/周期/随机/主动采样评估	scripts/evaluate_whisker_sampling_policies.py
真实硬件采样模式对比	scripts/compare_hardware_sampling_modes.py
移动机器人联合搜索环境	dual_whisker_rl/envs/mobile_whisker_env.py
动态 puff 羽流与基础触须环境	dual_whisker_rl/envs/whisker_only_env.py
底盘离散动力学	dual_whisker_rl/envs/robot_model.py
双触须扇区与采样点几何	dual_whisker_rl/envs/whisker_model.py
一阶/非对称气体传感器	dual_whisker_rl/envs/sensor_model.py
硬件一致 12 维观测	dual_whisker_rl/observation/whisker_observation_builder.py
MQ-3 在线预处理	dual_whisker_rl/hardware/sensor_preprocess.py
GRU 历史编码	dual_whisker_rl/agents/gru_history.py
Transformer 历史编码	dual_whisker_rl/agents/transformer_history.py
移动触须 PPO 训练	scripts/train_mobile_whisker_ppo.py
统一评估指标	dual_whisker_rl/evaluation.py
STM32 接口配置	configs/hardware.yaml + hardware/firmware/stm32_dual_whisker/

参考文献（初稿建议）

- [1] Sutton R S, Barto A G. Reinforcement Learning: An Introduction. 2nd ed. MIT Press, 2018.
- [2] Schulman J, Moritz P, Levine S, Jordan M, Abbeel P. High-Dimensional Continuous Control Using Generalized Advantage Estimation. ICLR, 2016.
- [3] Schulman J, Wolski F, Dhariwal P, Radford A, Klimov O. Proximal Policy Optimization Algorithms. arXiv:1707.06347, 2017.
- [4] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need. Advances in Neural Information Processing Systems, 2017.
- [5] Vergassola M, Villermanx E, Shraiman B I. Infotaxis as a Strategy for Searching without Gradients. Nature, 2007, 445: 406–409.

[6] Raffin A, Hill A, Gleave A, Kanervisto A, Ernestus M, Dormann N. Stable-Baselines3: Reliable Reinforcement Learning Implementations. *Journal of Machine Learning Research*, 2021, 22(268): 1–8.

[7] Towers M, Terry J K, Kwiatkowski A, et al. Gymnasium: A Standard Interface for Reinforcement Learning Environments. 2024. (正式投稿时按期刊要求核对版本与格式)

[8] Kowadlo G, Russell R A. Robot Odor Localization: A Taxonomy and Survey. *The International Journal of Robotics Research*, 2008, 27(8): 869–894. doi:10.1177/0278364908095118.

[9] Tao J, Meng Q H, Ishida H. Recent Progress and Trend of Robot Odor Source Localization. *IEEJ Transactions on Electrical and Electronic Engineering*, 2021, 16(7): 938–953. doi:10.1002/tee.23364.

[10] Singh S H, van Breugel F, Rao R P N, Brunton B W. Emergent Behaviour and Neural Dynamics in Artificial Agents Tracking Odour Plumes. *Nature Machine Intelligence*, 2023, 5: 58–70. doi:10.1038/s42256-022-00599-w.

[11] Loisy A, Heinen R A. Deep Reinforcement Learning for the Olfactory Search POMDP: A Quantitative Benchmark. *The European Physical Journal E*, 2023, 46: 17. doi:10.1140/epje/s10189-023-00277-8.

[12] Wang L, Pang S. Robotic Odor Source Localization via End-to-End Recurrent Deep Reinforcement Learning. 2023 IEEE 17th International Conference on Robotic Computing (IRC), 2023: 43–50. doi:10.1109/IRC59093.2023.00014.

[13] Monroy J, Hernandez-Bennetts V, Fan H, Lilienthal A J, Gonzalez-Jimenez J. GADEN: A 3D Gas Dispersion Simulator for Mobile Robot Olfaction in Realistic Environments. *Sensors*, 2017, 17(7): 1479. doi:10.3390/s17071479.

[14] Cho K, van Merriënboer B, Gulcehre C, et al. Learning Phrase Representations Using RNN Encoder–Decoder for Statistical Machine Translation. *Proceedings of EMNLP*, 2014: 1724–1734. doi:10.3115/v1/D14-1179.

初稿后续补充清单

- 补充 MQ-3 标准浓度标定、响应/恢复时间、重复性与两只传感器个体差异实验。
- 优先完成固定基座 active / fixed-multi / periodic / random-neighbor 的成对仿真与随机区组真机实验，先验证主动采样信息增益，再进入移动结论。
- 冻结环境版本后完成不少于 5 个训练 seed 的主方法正式训练，并保存 run_metadata、TensorBoard 和 checkpoint。
- 完成 fixed-whisker、MLP/GRU/Transformer、blank-age、reacquisition reward、domain randomization 等消融。

- 移动主比较统一使用同一 PPO、时序编码和训练预算，仅改变触须控制方式；增加 `progress_reward_scale=0` 的无距离塑形对照。
- 用统一 `evaluation.py` 生成成功率、路径、失嗅和重捕获指标，并进行统计显著性/置信区间分析。
- 以训练 seed 而非单个 episode 作为独立统计单位，预先指定主要指标并报告效应量与置信区间。
- 正式投稿前补充相关工作综述与近5年主动嗅觉/气味源定位深度强化学习文献，统一参考文献格式。
- 根据目标期刊/会议模板重新压缩章节、加入方法框图、网络结构图、羽流示意图、训练曲线、轨迹图和消融结果图。